Trabajo Práctico Final - Regresión Avanzada

Maestría en Explotación de Datos y Gestión del Conocimiento - Universidad Austral

Juan Ignacio Cacchione y Mariangeles Alomar

2026-05-18

Tabla de contenidos

1 Consigna I: Regresión Lineal **2**
1.1 Carga y exploración de datos . . . 2
1.2 Partición train/test (70/30) . . . 3
1.3 Ajuste de tres modelos de RLM por MCO . . . 3
1.4 Comparación de modelos: CME, PRESS, AIC y BIC . . . 5
1.5 Análisis de residuos . . . 6
1.5.1 Linealidad y homocedasticidad . . . 6
1.5.2 Normalidad de los residuos . . . 7
1.5.3 Independencia . . . 8
1.5.4 Colinealidad (VIF) . . . 9
1.5.5 Observaciones atípicas e influyentes . . . 9
1.6 Interpretación de coeficientes . . . 11

2 Consigna II: Regularización y Predicción **14**
2.1 Preparación de datos para glmnet . . . 14
2.2 Ajuste Ridge . . . 14
2.3 Ajuste Lasso . . . 16
2.4 Evaluación predictiva en datos de prueba . . . 19

3 Consigna III: Regresión Logística **21**
3.1 Definición de la variable respuesta binaria . . . 21
3.2 Partición train/test con createDataPartition . . . 21
3.3 Ajuste del modelo de regresión logística . . . 22
3.3.1 Razones de odds (OR) para predictores significativos al 5 % . . . 23
3.4 Punto de corte óptimo (Curva ROC) . . . 24
3.5 Clasificación y Matriz de Confusión en datos de prueba . . . 25
3.5.1 Métricas de clasificación . . . 26

1. Consigna I: Regresión Lineal

1.1. Carga y exploración de datos

```r
datos <- read_excel("eph.xlsx")

# Convertir variables categóricas a factor
datos <- datos %>%
  mutate(
    sexo      = factor(sexo),
    est_civil = factor(est_civil),
    region    = factor(region),
    educ_cat  = factor(educ_cat, levels = c("Ninguno", "Primario", "Secundario", "Superior")),
    formal    = factor(formal),
    ant_laboral = factor(ant_laboral, levels = c("Menos de 1 mes", "1 a 3 meses",
                                                 "Entre 3 y 6 meses", "6 meses a 1 año",
                                                 "1 a 5 años", "Mas de 5 años"))
  )

# Resumen general
glimpse(datos)
```

```
Rows: 10,208
Columns: 11
$ sexo               <fct> Hombre, Hombre, Hombre, Mujer, Hombre, Hombre, Muje~
$ edad               <dbl> 50, 29, 32, 29, 28, 50, 47, 28, 28, 44, 63, 28, 47,~
$ est_civil          <fct> casado, soltero, separado o divorciado, unido, unid~
$ region             <fct> Patagonia, Patagonia, Noreste, Patagonia, Patagonia~
$ educ_cat           <fct> Primario, Secundario, Secundario, Secundario, Secun~
$ ant_laboral        <fct> Mas de 5 años, 1 a 5 años, Mas de 5 años, Mas de 5 ~
$ formal             <fct> Si, Si, Si, Si, Si, Si, Si, Si, Si, Si, Si, Si, Si,~
$ horas_trabajo      <dbl> 35, 20, 30, 40, 48, 44, 40, 20, 54, 35, 48, 45, 40,~
$ ingreso_ocup       <dbl> 1200, 500, 430, 1000, 1000, 900, 700, 353, 700, 900~
$ ingreso_hogar      <dbl> 1200, 2700, 930, 4000, 4000, 1600, 1600, 1293, 1293~
$ ingreso_per_capita <dbl> 300.0000, 900.0000, 465.0000, 1000.0000, 1000.0000,~
```

Dado que `ingreso_hogar` e `ingreso_per_capita` se derivan directamente del ingreso de la ocupación principal (la variable respuesta), las excluimos como predictoras para evitar relaciones espurias. Los predictores disponibles son: `sexo`, `edad`, `est_civil`, `region`, `educ_cat`, `ant_laboral`, `formal` y `horas_trabajo`.

Dado que `ant_laboral` presenta 1033 valores faltantes, trabajaremos con las observaciones completas.

```
# Seleccionamos las columnas relevantes y eliminamos NAs
datos_modelo <- datos %>%
  dplyr::select(ingreso_ocup, sexo, edad, est_civil, region, educ_cat,
         ant_laboral, formal, horas_trabajo) %>%
  na.omit()

cat("Observaciones disponibles (sin NA):", nrow(datos_modelo), "\n")
```

```
Observaciones disponibles (sin NA): 9175
```

1.2. Partición train/test (70/30)

```
set.seed(2026)
n <- nrow(datos_modelo)
idx_train <- sample(seq_len(n), size = floor(0.70 * n))

train <- datos_modelo[idx_train, ]
test  <- datos_modelo[-idx_train, ]

cat("Train:", nrow(train), "| Test:", nrow(test), "\n")
```

```
Train: 6422 | Test: 2753
```

1.3. Ajuste de tres modelos de RLM por MCO

Proponemos tres modelos con distintas estrategias de selección de variables:

- **Modelo 1 (Criterio propio):** incluye las variables que, por sentido común del problema, deberían asociarse al ingreso: `sexo`, `edad`, `educ_cat`, `formal` y `horas_trabajo`.
- **Modelo 2 (Forward Selection por AIC):** se parte de un modelo nulo y se incorporan predictores de a uno, eligiendo en cada paso aquel que más reduzca el AIC.
- **Modelo 3 (Modelo completo):** incluye todos los predictores disponibles.

```
M1 <- lm(ingreso_ocup ~ sexo + edad + educ_cat + formal + horas_trabajo,
          data = train)
```

```r
# Forward Selection por AIC
modelo_nulo    <- lm(ingreso_ocup ~ 1, data = train)
modelo_maximo  <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
                        ant_laboral + formal + horas_trabajo, data = train)

M2 <- stepAIC(modelo_nulo,
              scope = list(upper = modelo_maximo),
              direction = "forward",
              trace = FALSE, k = 2)
summary(M2)
```

```
Call:
lm(formula = ingreso_ocup ~ formal + horas_trabajo + region +
    educ_cat + edad + sexo + est_civil + ant_laboral, data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-1498.7  -292.9   -74.0   151.3  9073.0

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                    -156.3916    94.8151  -1.649 0.099107 .
formalSi                        326.2601    17.8508  18.277  < 2e-16 ***
horas_trabajo                    10.6605     0.4847  21.994  < 2e-16 ***
regionGran Buenos Aires         132.4558    29.2710   4.525 6.14e-06 ***
regionNoreste                  -132.0093    33.9841  -3.884 0.000104 ***
regionNoroeste                 -139.3807    26.0190  -5.357 8.76e-08 ***
regionPampeana                   94.2209    25.6160   3.678 0.000237 ***
regionPatagonia                 376.3633    29.7081  12.669  < 2e-16 ***
educ_catPrimario                 43.4510    51.5338   0.843 0.399173
educ_catSecundario              170.5507    50.8827   3.352 0.000807 ***
educ_catSuperior                502.9233    52.1128   9.651  < 2e-16 ***
edad                              4.1317     0.7425   5.565 2.73e-08 ***
sexoMujer                      -144.6162    15.3694  -9.409  < 2e-16 ***
est_civilseparado o divorciado -111.3200    28.8668  -3.856 0.000116 ***
est_civilsoltero               -118.1565    21.0940  -5.601 2.21e-08 ***
est_civilunido                  -44.3525    20.1793  -2.198 0.027991 *
est_civilviudo                 -178.3733    65.1660  -2.737 0.006213 **
ant_laboral1 a 3 meses          168.9406    78.0586   2.164 0.030480 *
ant_laboralEntre 3 y 6 meses    127.2104    78.4437   1.622 0.104922
```

```
ant_laboral6 meses a 1 año       93.6701    76.8113   1.219 0.222706
ant_laboral1 a 5 años           148.4032    71.3995   2.078 0.037704 *
ant_laboralMas de 5 años        224.0193    71.9585   3.113 0.001859 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 557.8 on 6400 degrees of freedom
Multiple R-squared:  0.3455,    Adjusted R-squared:  0.3434
F-statistic: 160.9 on 21 and 6400 DF,  p-value: < 2.2e-16
```

```r
M3 <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
            ant_laboral + formal + horas_trabajo, data = train)
```

1.4. Comparación de modelos: CME, PRESS, AIC y BIC

```r
# Función para calcular métricas
metricas <- function(modelo, nombre) {
  n <- length(residuals(modelo))
  p <- length(coefficients(modelo))
  SCE <- deviance(modelo)

  # CME
  cme <- SCE / (n - p)

  # PRESS (suma de residuos PRESS al cuadrado)
  press_val <- sum((residuals(modelo) / (1 - hatvalues(modelo)))^2)

  # AIC y BIC
  aic_val <- AIC(modelo)
  bic_val <- BIC(modelo)

  tibble(Modelo = nombre, CME = round(cme, 2), PRESS = round(press_val, 0),
         AIC = round(aic_val, 2), BIC = round(bic_val, 2))
}

tabla_comp <- bind_rows(
  metricas(M1, "M1 - Criterio propio"),
  metricas(M2, "M2 - Forward AIC"),
  metricas(M3, "M3 - Completo")
)
```

```r
kable(tabla_comp, caption = "Comparación de modelos candidatos") %>%
  kable_styling(latex_options = c("hold_position", "striped"), full_width = FALSE)
```

Tabla 1: Comparación de modelos candidatos

Modelo	CME	PRESS	AIC	BIC
M1 - Criterio propio	340710.0	2190937327	100043.33	100104.2
M2 - Forward AIC	311183.1	2004430370	99475.14	99630.8
M3 - Completo	311183.1	2004430370	99475.14	99630.8

En los tres criterios de penalización (AIC y BIC), así como en el CME y el PRESS, buscamos los valores más bajos. El modelo seleccionado por Forward (M2) debería presentar un buen balance entre ajuste y complejidad. **Elegimos el modelo M2 como ganador**, ya que logra métricas competitivas con una selección objetiva de variables.

A continuación verificamos las variables incluidas en M2:

```r
cat("Variables del modelo ganador (M2):\n")
```

```
Variables del modelo ganador (M2):
```

```r
cat(paste(names(coef(M2)), collapse = ", "), "\n")
```

```
(Intercept), formalSi, horas_trabajo, regionGran Buenos Aires, regionNoreste, regionNoroeste, r
```

Para las consignas siguientes, trabajaremos con el **Modelo M2** (modelo ganador).

1.5. Análisis de residuos

1.5.1. Linealidad y homocedasticidad

```r
diag_m2 <- augment(M2)

ggplot(diag_m2, aes(x = .fitted, y = .resid)) +
  geom_point(alpha = 0.3, size = 1) +
  geom_hline(yintercept = 0, color = "red", linetype = "dashed") +
  geom_smooth(se = FALSE, color = "blue", linewidth = 0.8) +
  labs(x = "Valores ajustados", y = "Residuos")
```

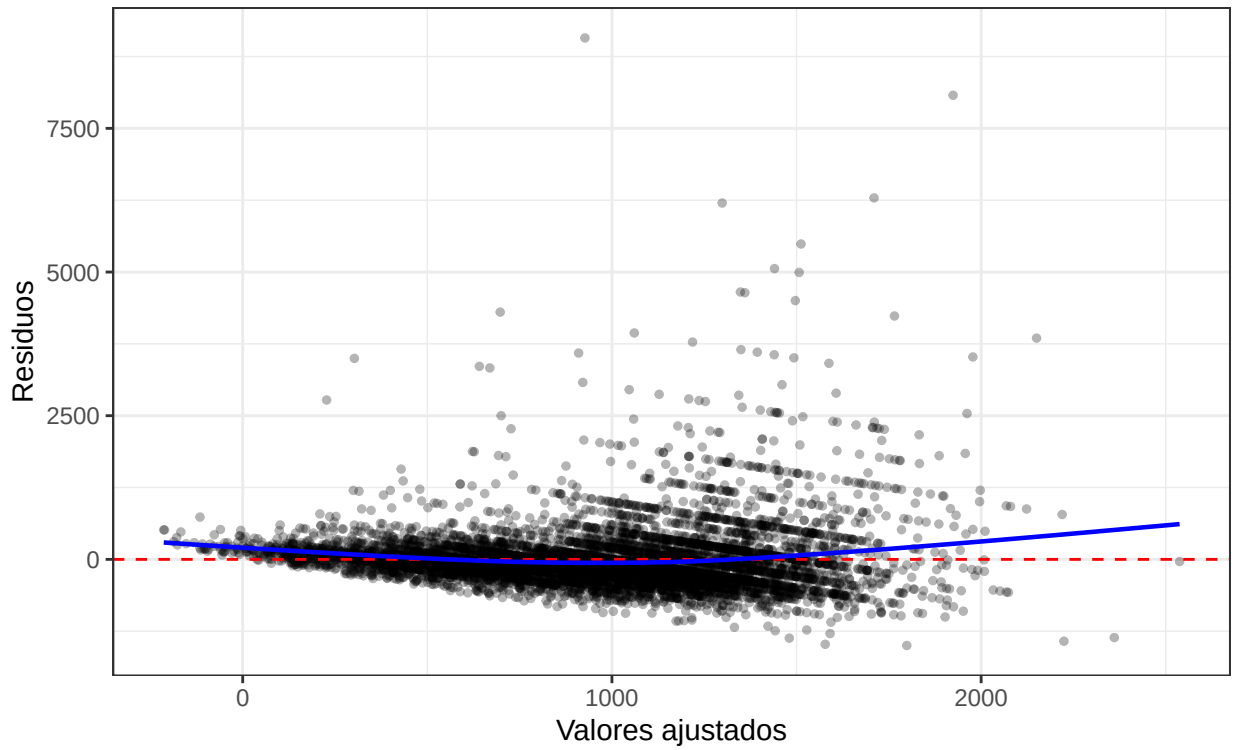

Figura 1: Residuos vs Valores Ajustados

```
# Test de Breusch-Pagan para homocedasticidad
bp_test <- bptest(M2)
bp_test
```

```
    studentized Breusch-Pagan test

data:  M2
BP = 122.95, df = 21, p-value < 2.2e-16
```

1.5.2. Normalidad de los residuos

```
ggplot(diag_m2, aes(sample = .resid)) +
  stat_qq(alpha = 0.3) +
  stat_qq_line(color = "red") +
  labs(x = "Cuantiles teóricos", y = "Cuantiles muestrales")
```

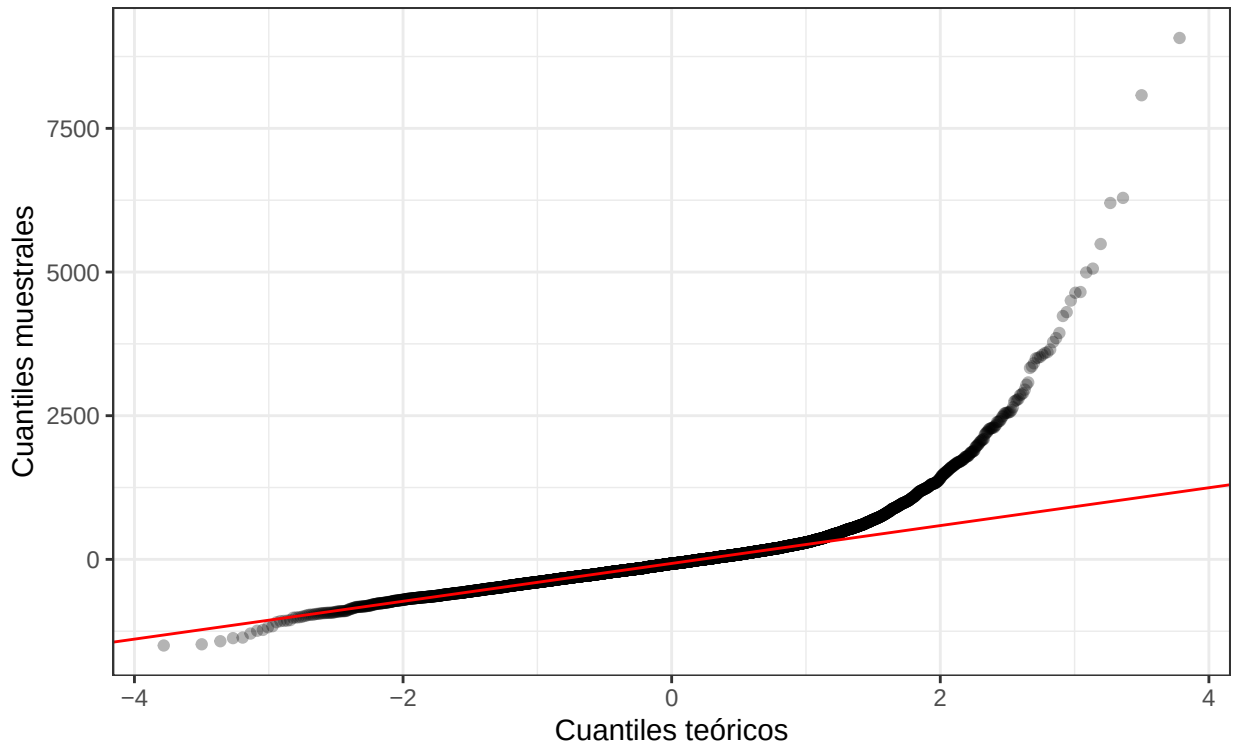

Figura 2: QQ-Plot de los residuos

```
# Test de Shapiro-Wilk (sobre una submuestra si n > 5000)
set.seed(123)
if (nrow(diag_m2) > 5000) {
  idx_shapiro <- sample(nrow(diag_m2), 5000)
  shapiro_test <- shapiro.test(diag_m2$.resid[idx_shapiro])
} else {
  shapiro_test <- shapiro.test(diag_m2$.resid)
}
shapiro_test
```

```
    Shapiro-Wilk normality test

data:  diag_m2$.resid[idx_shapiro]
W = 0.75281, p-value < 2.2e-16
```

1.5.3. Independencia

```r
# Test de Durbin-Watson
dw_test <- dwtest(M2)
dw_test
```

```
    Durbin-Watson test

data:  M2
DW = 2.0232, p-value = 0.8238
alternative hypothesis: true autocorrelation is greater than 0
```

1.5.4. Colinealidad (VIF)

```r
vif_vals <- vif(M2)
kable(as.data.frame(vif_vals), caption = "Factores de Inflación de la Varianza (VIF/GVIF)",
      digits = 3) %>%
  kable_styling(latex_options = c("hold_position", "striped"), full_width = FALSE)
```

Tabla 2: Factores de Inflación de la Varianza (VIF/GVIF)

	GVIF	Df	GVIF^(1/(2*Df))
formal	1.410	1	1.187
horas_trabajo	1.099	1	1.048
region	1.084	5	1.008
educ_cat	1.286	3	1.043
edad	1.685	1	1.298
sexo	1.178	1	1.086
est_civil	1.474	4	1.050
ant_laboral	1.567	5	1.046

Para variables categóricas, se reporta el GVIF ajustado por grados de libertad ($GVIF^{1/(2 \cdot Df)}$). Valores superiores a 5 (o $\sqrt{5} \approx 2.24$ en la escala ajustada) indican problemas de colinealidad.

1.5.5. Observaciones atípicas e influyentes

```r
# Distancia de Cook
cook_d <- cooks.distance(M2)
n_train <- nrow(train)
umbral_cook <- 4 / n_train

cat("Umbral de Cook (4/n):", round(umbral_cook, 6), "\n")
```

```
Umbral de Cook (4/n): 0.000623
```

```r
cat("Obs. con Cook > umbral:", sum(cook_d > umbral_cook), "\n")
```

```
Obs. con Cook > umbral: 220
```

```r
# Gráfico
plot(M2, which = 4, cook.levels = umbral_cook)
```

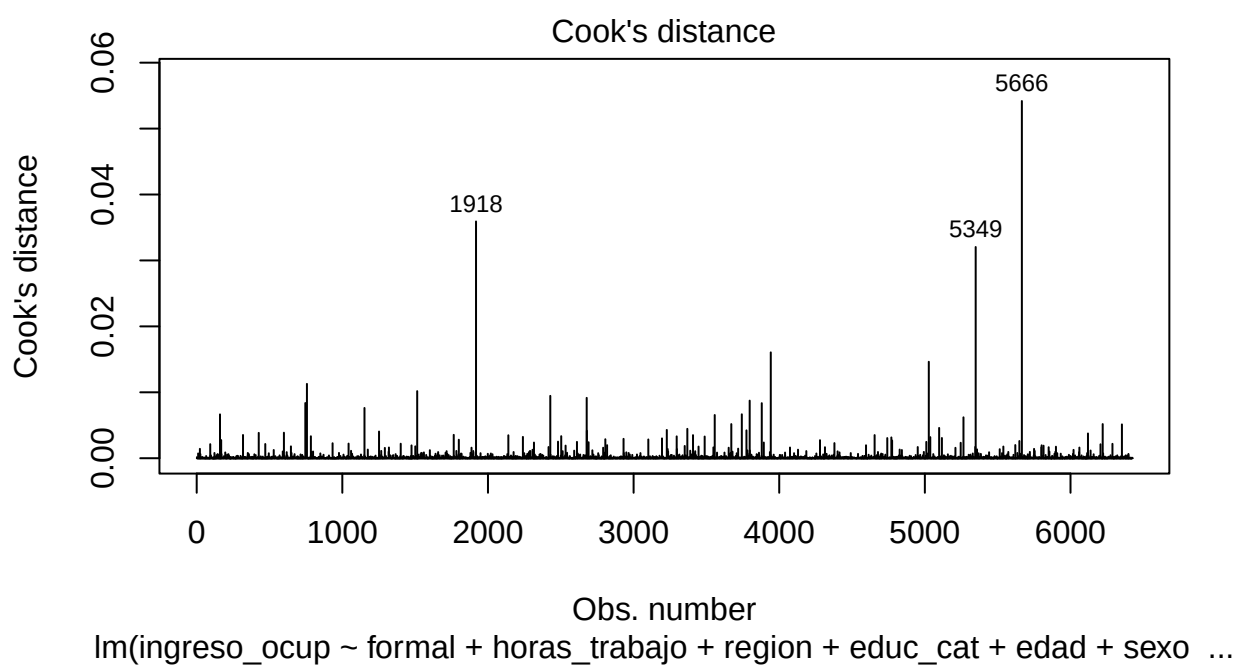

Figura 3: Distancia de Cook

```r
plot(M2, which = 5)
```

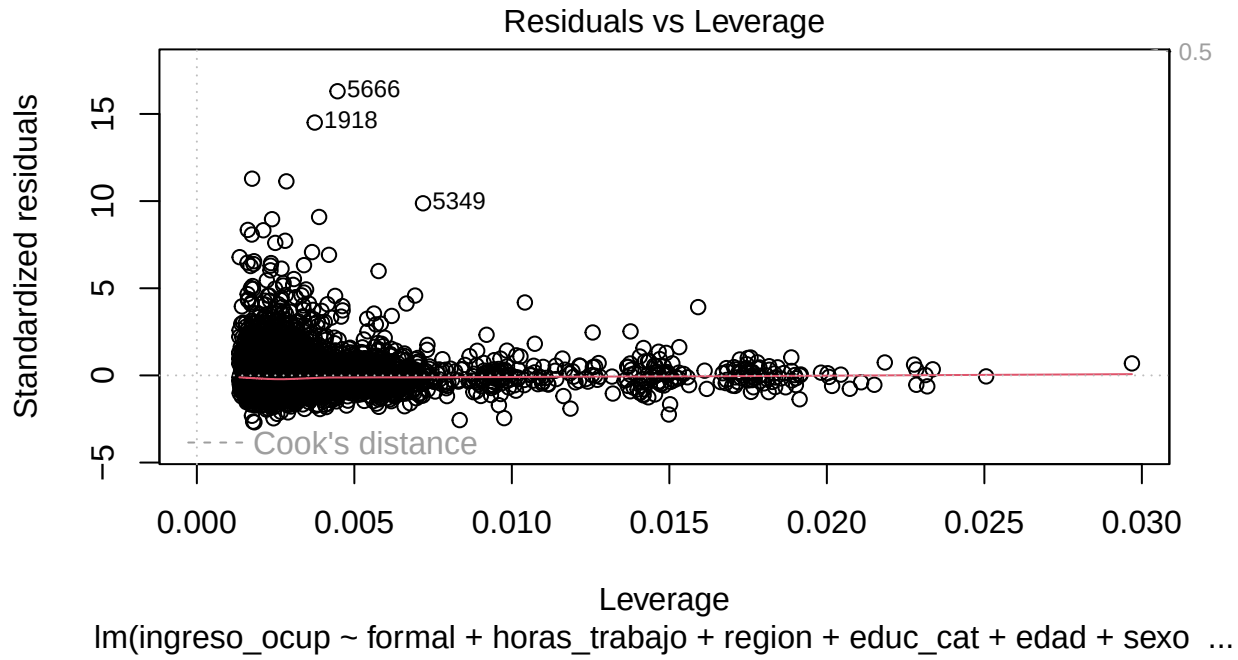

Figura 4: Residuos estudentizados vs Leverage

1.6. Interpretación de coeficientes

```
summary(M2)
```

```
Call:
lm(formula = ingreso_ocup ~ formal + horas_trabajo + region +
    educ_cat + edad + sexo + est_civil + ant_laboral, data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-1498.7  -292.9   -74.0   151.3  9073.0

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                  -156.3916    94.8151  -1.649 0.099107 .
formalSi                      326.2601    17.8508  18.277  < 2e-16 ***
horas_trabajo                  10.6605     0.4847  21.994  < 2e-16 ***
regionGran Buenos Aires       132.4558    29.2710   4.525 6.14e-06 ***
```

```
regionNoreste                  -132.0093    33.9841  -3.884 0.000104 ***
regionNoroeste                 -139.3807    26.0190  -5.357 8.76e-08 ***
regionPampeana                   94.2209    25.6160   3.678 0.000237 ***
regionPatagonia                 376.3633    29.7081  12.669  < 2e-16 ***
educ_catPrimario                 43.4510    51.5338   0.843 0.399173
educ_catSecundario              170.5507    50.8827   3.352 0.000807 ***
educ_catSuperior                502.9233    52.1128   9.651  < 2e-16 ***
edad                              4.1317     0.7425   5.565 2.73e-08 ***
sexoMujer                      -144.6162    15.3694  -9.409  < 2e-16 ***
est_civilseparado o divorciado -111.3200    28.8668  -3.856 0.000116 ***
est_civilsoltero               -118.1565    21.0940  -5.601 2.21e-08 ***
est_civilunido                  -44.3525    20.1793  -2.198 0.027991 *
est_civilviudo                 -178.3733    65.1660  -2.737 0.006213 **
ant_laboral1 a 3 meses          168.9406    78.0586   2.164 0.030480 *
ant_laboralEntre 3 y 6 meses    127.2104    78.4437   1.622 0.104922
ant_laboral6 meses a 1 año       93.6701    76.8113   1.219 0.222706
ant_laboral1 a 5 años           148.4032    71.3995   2.078 0.037704 *
ant_laboralMas de 5 años        224.0193    71.9585   3.113 0.001859 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 557.8 on 6400 degrees of freedom
Multiple R-squared:  0.3455,    Adjusted R-squared:  0.3434
F-statistic: 160.9 on 21 and 6400 DF,  p-value: < 2.2e-16
```

```r
# Tabla de coeficientes con IC al 95%
coef_tabla <- tidy(M2, conf.int = TRUE) %>%
  mutate(across(where(is.numeric), ~round(., 4)))

kable(coef_tabla, caption = "Coeficientes estimados del modelo M2",
      col.names = c("Término", "Estimación", "Error Std.", "t", "p-valor",
                    "IC 2.5%", "IC 97.5%")) %>%
  kable_styling(latex_options = c("hold_position", "striped", "scale_down"),
                full_width = FALSE)
```

Tabla 3: Coeficientes estimados del modelo M2

Término	Estimación	Error Std.	t	p-valor	IC 2.5%	IC 97.5%
(Intercept)	-156.3916	94.8151	-1.6494	0.0991	-342.2609	29.4776
formalSi	326.2601	17.8508	18.2770	0.0000	291.2665	361.2537
horas_trabajo	10.6605	0.4847	21.9939	0.0000	9.7103	11.6107

regionGran Buenos Aires	132.4558	29.2710	4.5252	0.0000	75.0749	189.8367
regionNoreste	-132.0093	33.9841	-3.8844	0.0001	-198.6295	-65.3892
regionNoroeste	-139.3807	26.0190	-5.3569	0.0000	-190.3867	-88.3748
regionPampeana	94.2209	25.6160	3.6782	0.0002	44.0049	144.4368
regionPatagonia	376.3633	29.7081	12.6687	0.0000	318.1254	434.6011
educ_catPrimario	43.4510	51.5338	0.8432	0.3992	-57.5725	144.4746
educ_catSecundario	170.5507	50.8827	3.3518	0.0008	70.8035	270.2978
educ_catSuperior	502.9233	52.1128	9.6507	0.0000	400.7648	605.0817
edad	4.1317	0.7425	5.5647	0.0000	2.6762	5.5872
sexoMujer	-144.6162	15.3694	-9.4094	0.0000	-174.7453	-114.4871
est_civilseparado o divorciado	-111.3200	28.8668	-3.8563	0.0001	-167.9085	-54.7314
est_civilsoltero	-118.1565	21.0940	-5.6014	0.0000	-159.5078	-76.8052
est_civilunido	-44.3525	20.1793	-2.1979	0.0280	-83.9108	-4.7942
est_civilviudo	-178.3733	65.1660	-2.7372	0.0062	-306.1205	-50.6262
ant_laboral1 a 3 meses	168.9406	78.0586	2.1643	0.0305	15.9195	321.9616
ant_laboralEntre 3 y 6 meses	127.2104	78.4437	1.6217	0.1049	-26.5655	280.9863
ant_laboral6 meses a 1 año	93.6701	76.8113	1.2195	0.2227	-56.9058	244.2460
ant_laboral1 a 5 años	148.4032	71.3995	2.0785	0.0377	8.4362	288.3701
ant_laboralMas de 5 años	224.0193	71.9585	3.1132	0.0019	82.9565	365.0821

Interpretación de los efectos (sobre el ingreso por ocupación principal, en miles de pesos):

A continuación se interpretan los predictores incluidos en el modelo. Cada coeficiente representa el cambio esperado en `ingreso_ocup` (en miles de pesos) ante un cambio unitario en el predictor, manteniendo las demás variables constantes.

- **Sexo:** las mujeres perciben, en promedio, un ingreso menor que los hombres (categoría de referencia), manteniendo el resto constante.
- **Edad:** por cada año adicional de edad, se espera un cambio en el ingreso que refleja la acumulación de experiencia.
- **Educación:** mayores niveles educativos se asocian con mayores ingresos esperados respecto a la categoría *Ninguno*.
- **Formalidad:** los trabajadores formales perciben significativamente más que los informales.
- **Horas de trabajo:** cada hora adicional trabajada por semana se asocia con un incremento en el ingreso esperado.

Los p-valores del test t para cada coeficiente indican si la relación es estadísticamente significativa al 5 %.

2. Consigna II: Regularización y Predicción

2.1. Preparación de datos para glmnet

```
# glmnet requiere una matriz X numérica
# Usamos model.matrix para generar las dummies
X_train <- model.matrix(M2, data = train)[, -1]  # Sin intercepto
y_train <- train$ingreso_ocup

X_test <- model.matrix(M2, data = test)[, -1]
y_test <- test$ingreso_ocup
```

2.2. Ajuste Ridge

```
set.seed(2026)
cv_ridge <- cv.glmnet(
  x = X_train, y = y_train,
  alpha = 0,   # Ridge
  nfolds = 10
)
plot(cv_ridge)
```

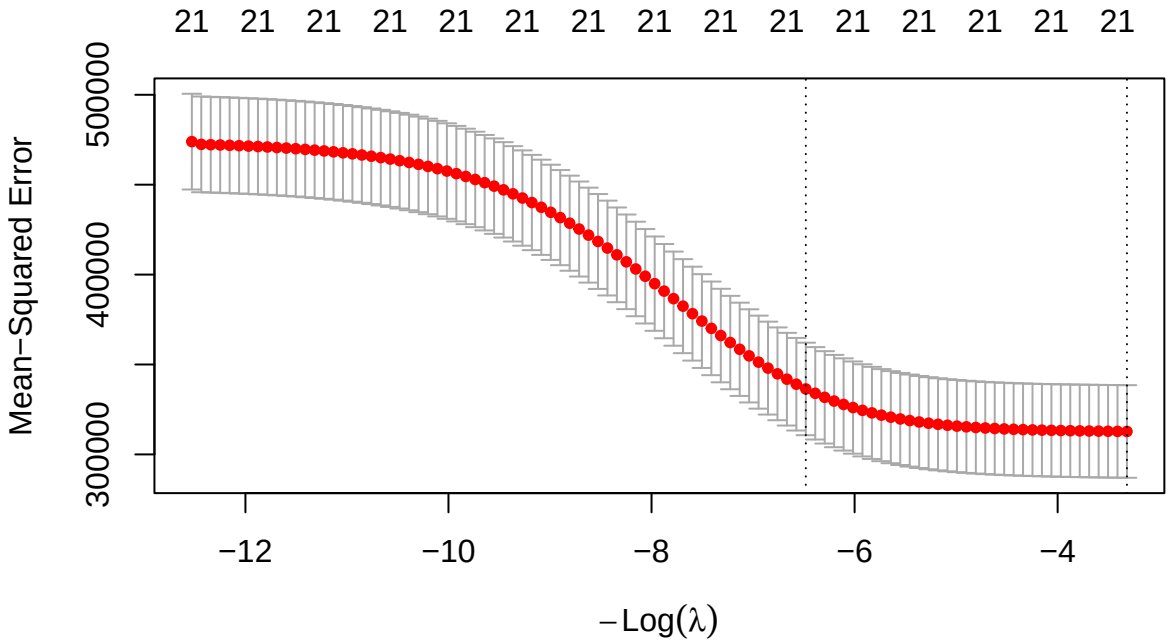

Figura 5: Validación cruzada para Ridge

```
cat("Lambda óptimo Ridge:", cv_ridge$lambda.min, "\n")
```

```
Lambda óptimo Ridge: 27.58713
```

```
# Ajuste con lambda óptimo
m_ridge <- glmnet(x = X_train, y = y_train, alpha = 0, lambda = cv_ridge$lambda.min)

# Comparación de coeficientes MCO vs Ridge
coef_mco   <- coef(M2)
coef_ridge <- as.vector(coef(m_ridge))
nombres    <- names(coef_mco)

comp_ridge <- data.frame(
  Termino = nombres,
  MCO     = round(coef_mco, 4),
  Ridge   = round(coef_ridge, 4)
)

kable(comp_ridge, caption = "Comparación de coeficientes: MCO vs Ridge",
      row.names = FALSE) %>%
```

```
kable_styling(latex_options = c("hold_position", "striped", "scale_down"),
              full_width = FALSE)
```

Tabla 4: Comparación de coeficientes: MCO vs Ridge

Termino	MCO	Ridge
(Intercept)	-156.3916	120.3910
formalSi	326.2601	325.0741
horas_trabajo	10.6605	10.3053
regionGran Buenos Aires	132.4558	115.9544
regionNoreste	-132.0093	-137.4698
regionNoroeste	-139.3807	-148.3879
regionPampeana	94.2209	77.1823
regionPatagonia	376.3633	353.8742
educ_catPrimario	43.4510	-86.3102
educ_catSecundario	170.5507	37.0115
educ_catSuperior	502.9233	357.8937
edad	4.1317	4.0018
sexoMujer	-144.6162	-135.8488
est_civilseparado o divorciado	-111.3200	-102.1878
est_civilsoltero	-118.1565	-109.9952
est_civilunido	-44.3525	-37.6294
est_civilviudo	-178.3733	-179.7710
ant_laboral1 a 3 meses	168.9406	39.3699
ant_laboralEntre 3 y 6 meses	127.2104	0.7694
ant_laboral6 meses a 1 año	93.6701	-29.0308
ant_laboral1 a 5 años	148.4032	24.7063
ant_laboralMas de 5 años	224.0193	104.1177

Se observa que los coeficientes Ridge son ligeramente menores en valor absoluto que los de MCO, lo cual es esperable dado que Ridge aplica una penalización cuadrática que *encoge* las estimaciones hacia cero.

2.3. Ajuste Lasso

```
set.seed(2026)
cv_lasso <- cv.glmnet(
```

```
  x = X_train, y = y_train,
  alpha = 1,   # Lasso
  nfolds = 10
)
plot(cv_lasso)
```

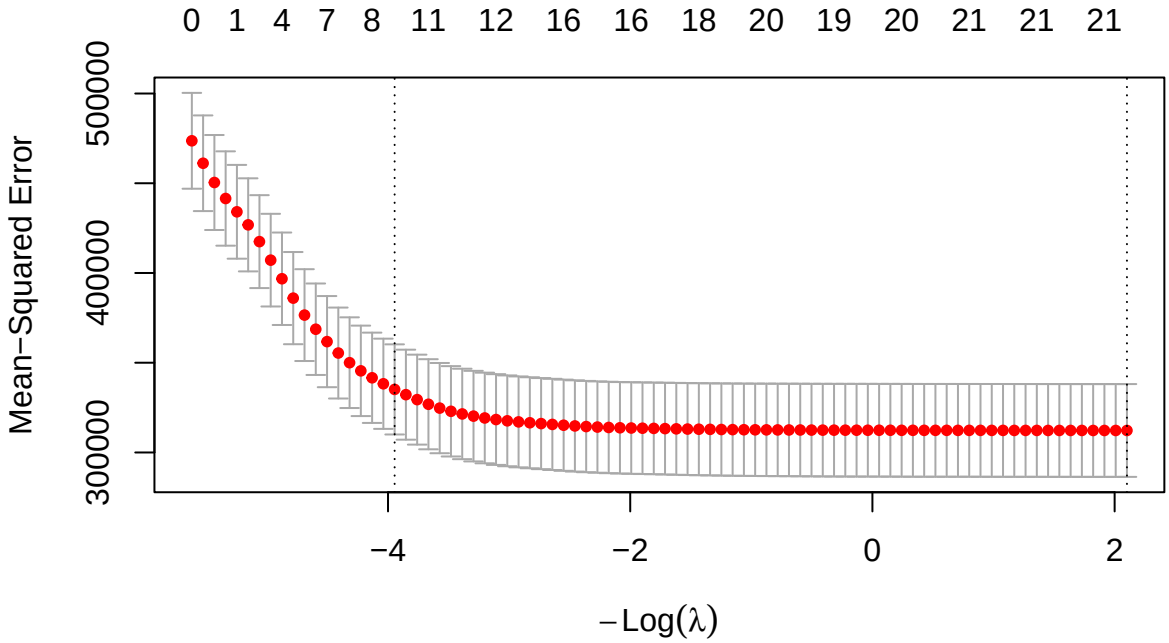

Figura 6: Validación cruzada para Lasso

```
cat("Lambda óptimo Lasso:", cv_lasso$lambda.min, "\n")
```

```
Lambda óptimo Lasso: 0.1222281
```

```
# Ajuste con lambda óptimo
m_lasso <- glmnet(x = X_train, y = y_train, alpha = 1, lambda = cv_lasso$lambda.min)

# Comparación de coeficientes MCO vs Lasso
coef_lasso <- as.vector(coef(m_lasso))

comp_lasso <- data.frame(
  Termino = nombres,
  MCO     = round(coef_mco, 4),
```

```r
  Lasso   = round(coef_lasso, 4)
)

kable(comp_lasso, caption = "Comparación de coeficientes: MCO vs Lasso",
      row.names = FALSE) %>%
  kable_styling(latex_options = c("hold_position", "striped", "scale_down"),
                full_width = FALSE)
```

Tabla 5: Comparación de coeficientes: MCO vs Lasso

Termino	MCO	Lasso
(Intercept)	-156.3916	-115.8483
formalSi	326.2601	327.0270
horas_trabajo	10.6605	10.6608
regionGran Buenos Aires	132.4558	131.3488
regionNoreste	-132.0093	-132.1485
regionNoroeste	-139.3807	-139.6848
regionPampeana	94.2209	93.0376
regionPatagonia	376.3633	375.5515
educ_catPrimario	43.4510	33.6935
educ_catSecundario	170.5507	160.9229
educ_catSuperior	502.9233	493.3473
edad	4.1317	4.1184
sexoMujer	-144.6162	-144.1634
est_civilseparado o divorciado	-111.3200	-110.1913
est_civilsoltero	-118.1565	-117.2072
est_civilunido	-44.3525	-43.4651
est_civilviudo	-178.3733	-177.4155
ant_laboral1 a 3 meses	168.9406	136.6847
ant_laboralEntre 3 y 6 meses	127.2104	94.9721
ant_laboral6 meses a 1 año	93.6701	61.5366
ant_laboral1 a 5 años	148.4032	116.6234
ant_laboralMas de 5 años	224.0193	192.6245

Lasso puede llevar algunos coeficientes exactamente a cero, realizando simultáneamente estimación y selección de variables. Si algún coeficiente resulta 0, indica que Lasso consideró prescindible esa variable.

2.4. Evaluación predictiva en datos de prueba

```r
# Predicciones
pred_mco   <- predict(M2, newdata = test)
pred_ridge <- predict(m_ridge, newx = X_test, s = cv_ridge$lambda.min)
pred_lasso <- predict(m_lasso, newx = X_test, s = cv_lasso$lambda.min)

# Error cuadrático medio de predicción (MSE)
mse_mco   <- mean((y_test - pred_mco)^2)
mse_ridge <- mean((y_test - as.vector(pred_ridge))^2)
mse_lasso <- mean((y_test - as.vector(pred_lasso))^2)

# RMSE
rmse_mco   <- sqrt(mse_mco)
rmse_ridge <- sqrt(mse_ridge)
rmse_lasso <- sqrt(mse_lasso)

# R2 de predicción
sct_test <- sum((y_test - mean(y_test))^2)
r2_mco   <- 1 - sum((y_test - pred_mco)^2) / sct_test
r2_ridge <- 1 - sum((y_test - as.vector(pred_ridge))^2) / sct_test
r2_lasso <- 1 - sum((y_test - as.vector(pred_lasso))^2) / sct_test

tabla_pred <- data.frame(
  Modelo = c("MCO", "Ridge", "Lasso"),
  MSE    = round(c(mse_mco, mse_ridge, mse_lasso), 2),
  RMSE   = round(c(rmse_mco, rmse_ridge, rmse_lasso), 2),
  R2_Pred = round(c(r2_mco, r2_ridge, r2_lasso), 4)
)

kable(tabla_pred, caption = "Capacidad predictiva en datos de prueba",
      col.names = c("Modelo", "MSE", "RMSE", "R² Predicción")) %>%
  kable_styling(latex_options = c("hold_position", "striped"), full_width = FALSE)
```

Tabla 6: Capacidad predictiva en datos de prueba

Modelo	MSE	RMSE	R^2 Predicción
MCO	377387.4	614.32	0.3000
Ridge	378422.0	615.16	0.2981
Lasso	377427.3	614.35	0.2999

El modelo con menor MSE/RMSE y mayor R^2 de predicción en el conjunto de prueba es el más adecuado para este ejemplo. En problemas donde la colinealidad no es severa y $n >> p$, es habitual que los tres métodos arrojen resultados similares.

3. Consigna III: Regresión Logística

3.1. Definición de la variable respuesta binaria

```
# Trabajamos con el dataset original completo (sin NAs en las variables del modelo)
datos_logit <- datos_modelo %>%
  mutate(Y = ifelse(ingreso_ocup >= 1000, 1, 0))

cat("Distribución de Y:\n")
```

```
Distribución de Y:
```

```
table(datos_logit$Y)
```

```
   0    1
5655 3520
```

```
cat("\nProporción de Y=1:", round(mean(datos_logit$Y), 4), "\n")
```

```
Proporción de Y=1: 0.3837
```

3.2. Partición train/test con createDataPartition

```
set.seed(2026)
idx_logit <- createDataPartition(datos_logit$Y, p = 0.70, list = FALSE)

train_logit <- datos_logit[idx_logit, ]
test_logit  <- datos_logit[-idx_logit, ]

cat("Train:", nrow(train_logit), "| Test:", nrow(test_logit), "\n")
```

```
Train: 6423 | Test: 2752
```

```
cat("Proporción Y=1 en Train:", round(mean(train_logit$Y), 4), "\n")
```

```
Proporción Y=1 en Train: 0.3875
```

```r
cat("Proporción Y=1 en Test: ", round(mean(test_logit$Y), 4), "\n")
```

```
Proporción Y=1 en Test:  0.3746
```

Se verifica que `createDataPartition()` mantiene la proporción de éxitos balanceada entre ambos conjuntos.

3.3. Ajuste del modelo de regresión logística

Utilizamos las mismas variables explicativas que el modelo ganador de la Consigna I.

```r
# Construimos la fórmula a partir de M2
vars_m2 <- names(coef(M2))[-1]  # sin intercepto
# Reconstruimos los nombres de las variables originales (sin niveles de factor)
vars_originales <- unique(gsub("(sexo|est_civil|region|educ_cat|ant_laboral|formal).*",
                               "\\1", vars_m2))

formula_logit <- as.formula(paste("Y ~", paste(vars_originales, collapse = " + ")))

MLog <- glm(formula_logit, data = train_logit, family = binomial(link = "logit"))
summary(MLog)
```

```
Call:
glm(formula = formula_logit, family = binomial(link = "logit"),
    data = train_logit)

Coefficients:
                              Estimate Std. Error z value Pr(>|z|)
(Intercept)                  -6.115474   0.605726 -10.096  < 2e-16 ***
formalSi                      1.699769   0.094614  17.965  < 2e-16 ***
horas_trabajo                 0.047273   0.002591  18.242  < 2e-16 ***
regionGran Buenos Aires       0.583426   0.132034   4.419 9.93e-06 ***
regionNoreste                -0.614444   0.156353  -3.930 8.50e-05 ***
regionNoroeste               -0.822909   0.125612  -6.551 5.71e-11 ***
regionPampeana                0.480778   0.117733   4.084 4.43e-05 ***
regionPatagonia               1.691959   0.137985  12.262  < 2e-16 ***
educ_catPrimario              0.349678   0.276905   1.263  0.20666
```

```
educ_catSecundario              1.142179   0.271940   4.200 2.67e-05 ***
educ_catSuperior                2.171311   0.276574   7.851 4.14e-15 ***
edad                            0.020326   0.003476   5.848 4.98e-09 ***
sexoMujer                      -0.747876   0.071978 -10.390  < 2e-16 ***
est_civilseparado o divorciado -0.548787   0.128838  -4.260 2.05e-05 ***
est_civilsoltero               -0.493374   0.093956  -5.251 1.51e-07 ***
est_civilunido                 -0.078270   0.088560  -0.884  0.37680
est_civilviudo                 -0.868035   0.320662  -2.707  0.00679 **
ant_laboral1 a 3 meses          0.348796   0.530779   0.657  0.51109
ant_laboralEntre 3 y 6 meses   -0.019585   0.531000  -0.037  0.97058
ant_laboral6 meses a 1 año      0.205583   0.515871   0.399  0.69025
ant_laboral1 a 5 años           0.577752   0.490281   1.178  0.23863
ant_laboralMas de 5 años        0.924854   0.490478   1.886  0.05935 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 8576.3  on 6422  degrees of freedom
Residual deviance: 5898.3  on 6401  degrees of freedom
AIC: 5942.3

Number of Fisher Scoring iterations: 5
```

3.3.1. Razones de odds (OR) para predictores significativos al 5 %

```r
# OR e intervalos de confianza
or_tabla <- tidy(MLog, conf.int = TRUE, exponentiate = TRUE) %>%
  filter(p.value < 0.05) %>%
  mutate(across(where(is.numeric), ~round(., 4)))

kable(or_tabla, caption = "Razones de Odds (OR) de predictores significativos (  = 0.05)",
      col.names = c("Término", "OR", "Error Std.", "z", "p-valor",
                    "OR IC 2.5%", "OR IC 97.5%")) %>%
  kable_styling(latex_options = c("hold_position", "striped", "scale_down"),
                full_width = FALSE)
```

Tabla 7: Razones de Odds (OR) de predictores significativos (= 0.05)

Término	OR	Error Std.	z	p-valor	OR IC 2.5 %	OR IC 97.5 %

(Intercept)	0.0022	0.6057	-10.0961	0.0000	0.0006	0.0069
formalSi	5.4727	0.0946	17.9654	0.0000	4.5550	6.6012
horas_trabajo	1.0484	0.0026	18.2421	0.0000	1.0431	1.0538
regionGran Buenos Aires	1.7922	0.1320	4.4188	0.0000	1.3845	2.3234
regionNoreste	0.5409	0.1564	-3.9299	0.0001	0.3977	0.7343
regionNoroeste	0.4392	0.1256	-6.5512	0.0000	0.3433	0.5618
regionPampeana	1.6173	0.1177	4.0836	0.0000	1.2850	2.0390
regionPatagonia	5.4301	0.1380	12.2619	0.0000	4.1496	7.1282
educ_catSecundario	3.1336	0.2719	4.2001	0.0000	1.8659	5.4367
educ_catSuperior	8.7698	0.2766	7.8507	0.0000	5.1742	15.3501
edad	1.0205	0.0035	5.8477	0.0000	1.0136	1.0275
sexoMujer	0.4734	0.0720	-10.3903	0.0000	0.4109	0.5448
est_civilseparado o divorciado	0.5777	0.1288	-4.2595	0.0000	0.4484	0.7432
est_civilsoltero	0.6106	0.0940	-5.2511	0.0000	0.5078	0.7339
est_civilviudo	0.4198	0.3207	-2.7070	0.0068	0.2199	0.7759

Interpretación de las OR: una razón de odds mayor a 1 indica que ese nivel del predictor aumenta las chances de percibir un ingreso 1000 miles de pesos (respecto a la categoría de referencia), mientras que un OR menor a 1 las disminuye, manteniendo las demás variables constantes.

3.4. Punto de corte óptimo (Curva ROC)

```r
prob_train <- predict(MLog, type = "response")

curvaROC <- roc(
  response  = train_logit$Y,
  predictor = prob_train,
  quiet     = TRUE
)

plot(curvaROC, print.auc = TRUE, print.thres = TRUE,
     main = "Curva ROC - Modelo Logístico")
```

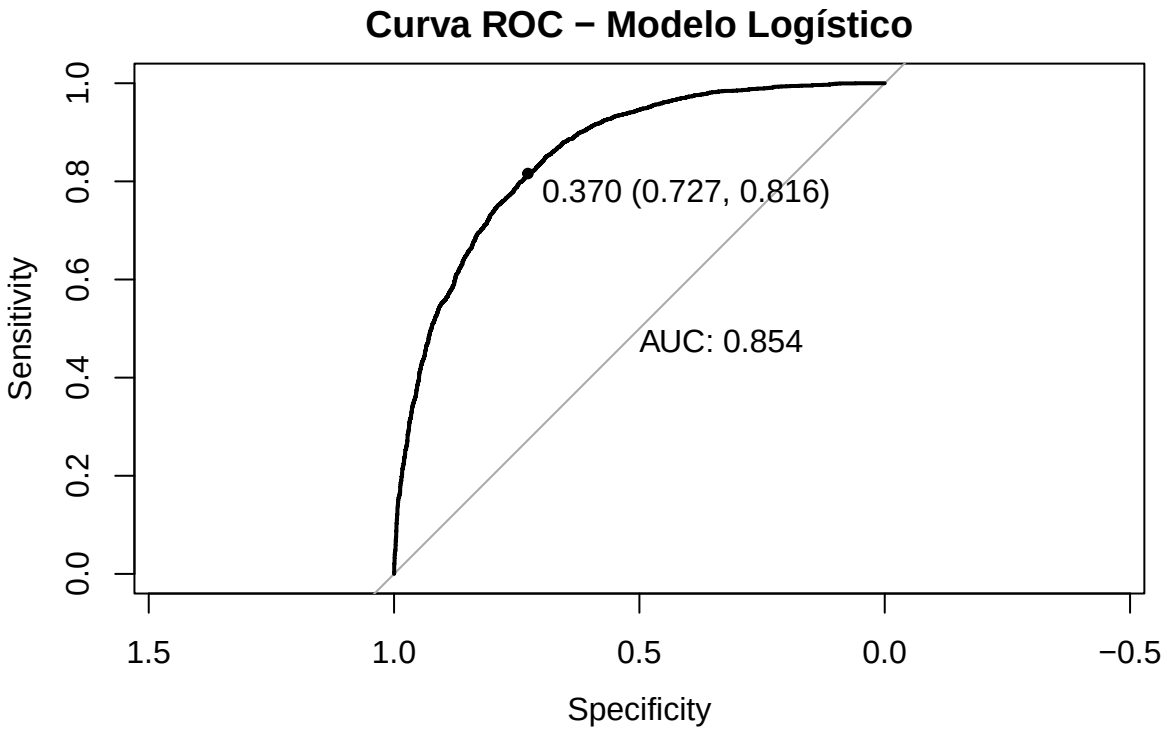

Figura 7: Curva ROC del modelo logístico

```
# Punto de corte óptimo
corte_optimo <- coords(curvaROC, "best", ret = "threshold")
cat("Punto de corte óptimo:", corte_optimo$threshold, "\n")
```

```
Punto de corte óptimo: 0.369624
```

```
cat("AUC:", auc(curvaROC), "\n")
```

```
AUC: 0.8540701
```

El punto de corte óptimo es aquel que maximiza simultáneamente la sensibilidad y la especificidad.

3.5. Clasificación y Matriz de Confusión en datos de prueba

```
# Probabilidades predichas en test
prob_test <- predict(MLog, newdata = test_logit, type = "response")

# Clasificación con el corte óptimo
```

```r
pred_clase <- factor(ifelse(prob_test >= corte_optimo$threshold, 1, 0),
                     levels = c("0", "1"))
real_clase <- factor(test_logit$Y, levels = c("0", "1"))

# Matriz de confusión
mc <- confusionMatrix(pred_clase, real_clase, positive = "1")
mc
```

```
Confusion Matrix and Statistics

          Reference
Prediction    0    1
         0 1215  217
         1  506  814

               Accuracy : 0.7373
                 95% CI : (0.7204, 0.7536)
    No Information Rate : 0.6254
    P-Value [Acc > NIR] : < 2.2e-16

                  Kappa : 0.4691

 Mcnemar's Test P-Value : < 2.2e-16

            Sensitivity : 0.7895
            Specificity : 0.7060
         Pos Pred Value : 0.6167
         Neg Pred Value : 0.8485
             Prevalence : 0.3746
         Detection Rate : 0.2958
   Detection Prevalence : 0.4797
      Balanced Accuracy : 0.7478

       'Positive' Class : 1
```

3.5.1. Métricas de clasificación

```r
metricas_clas <- data.frame(
  Metrica = c("Precisión (Accuracy)", "Sensibilidad", "Especificidad", "VPP", "VPN"),
```

```r
  Valor   = round(c(
    mc$overall["Accuracy"],
    mc$byClass["Sensitivity"],
    mc$byClass["Specificity"],
    mc$byClass["Pos Pred Value"],
    mc$byClass["Neg Pred Value"]
  ), 4)
)

kable(metricas_clas, caption = "Métricas de clasificación en datos de prueba",
      row.names = FALSE) %>%
  kable_styling(latex_options = c("hold_position", "striped"), full_width = FALSE)
```

Tabla 8: Métricas de clasificación en datos de prueba

Metrica	Valor
Precisión (Accuracy)	0.7373
Sensibilidad	0.7895
Especificidad	0.7060
VPP	0.6167
VPN	0.8485

Interpretación:

- **Precisión (Accuracy):** proporción total de individuos correctamente clasificados.
- **Sensibilidad:** proporción de individuos con ingreso 1000 (Y=1) correctamente identificados. Mide la capacidad del modelo para detectar los verdaderos positivos.
- **Especificidad:** proporción de individuos con ingreso $<$ 1000 (Y=0) correctamente identificados. Mide la capacidad del modelo para detectar los verdaderos negativos.
- **VPP (Valor Predictivo Positivo):** cuando el modelo predice Y=1, esta es la proporción de veces que acierta.
- **VPN (Valor Predictivo Negativo):** cuando el modelo predice Y=0, esta es la proporción de veces que acierta.