Trabajo Práctico Final - Regresión Avanzada

Maestría en Explotación de Datos y Gestión del Conocimiento - Universidad Austral

Juan Ignacio Cacchione y Mariangeles Alomar

2026-05-18

Tabla de contenidos

1 Consigna I: Regresión Lineal **2**
1.1 Carga y exploración de datos . . . 2
1.2 Partición train/test (70/30) . . . 2
1.3 Ajuste de tres modelos de RLM por MCO . . . 3
1.4 Comparación de modelos: CME, PRESS, AIC y BIC . . . 3
1.5 Análisis de residuos . . . 4
1.5.1 Linealidad y homocedasticidad . . . 4
1.5.2 Normalidad de los residuos . . . 5
1.5.3 Independencia . . . 6
1.5.4 Colinealidad (VIF) . . . 7
1.5.5 Observaciones atípicas e influyentes . . . 7
1.6 Interpretación de coeficientes . . . 8

2 Consigna II: Regularización y Predicción **10**
2.1 Preparación de datos para glmnet . . . 10
2.2 Ajuste Ridge . . . 10
2.3 Ajuste Lasso . . . 11
2.4 Evaluación predictiva en datos de prueba . . . 13

3 Consigna III: Regresión Logística **15**
3.1 Definición de la variable respuesta binaria . . . 15
3.2 Partición train/test con createDataPartition . . . 15
3.3 Ajuste del modelo de regresión logística . . . 16
3.3.1 Razones de odds (OR) para predictores significativos al 5 % . . . 17
3.4 Punto de corte óptimo (Curva ROC) . . . 17
3.5 Clasificación y Matriz de Confusión en datos de prueba . . . 18
3.5.1 Métricas de clasificación . . . 19

1. Consigna I: Regresión Lineal

1.1. Carga y exploración de datos

```
datos <- read_excel("eph.xlsx")

datos <- datos %>%
  mutate(
    sexo      = factor(sexo),
    est_civil = factor(est_civil),
    region    = factor(region),
    educ_cat  = factor(educ_cat, levels = c("Ninguno","Primario","Secundario","Superior")),
    formal    = factor(formal),
    ant_laboral = factor(ant_laboral,
                         levels = c("Menos de 1 mes","1 a 3 meses","Entre 3 y 6 meses",
                                    "6 meses a 1 año","1 a 5 años","Mas de 5 años"))
  )

str(datos)
```

```
tibble [10,208 x 11] (S3: tbl_df/tbl/data.frame)
 $ sexo              : Factor w/ 2 levels "Hombre","Mujer": 1 1 1 2 1 1 2 2 1 1 ...
 $ edad              : num [1:10208] 50 29 32 29 28 50 47 28 28 44 ...
 $ est_civil         : Factor w/ 5 levels "casado","separado o divorciado",..: 1 3 2 4 4 4 4 4
 $ region            : Factor w/ 6 levels "Cuyo","Gran Buenos Aires",..: 6 6 3 6 6 4 4 5 5 6 ..
 $ educ_cat          : Factor w/ 4 levels "Ninguno","Primario",..: 2 3 3 3 3 3 3 3 2 3 ...
 $ ant_laboral       : Factor w/ 6 levels "Menos de 1 mes",..: 6 5 6 6 2 6 6 NA 5 6 ...
 $ formal            : Factor w/ 2 levels "No","Si": 2 2 2 2 2 2 2 2 2 2 ...
 $ horas_trabajo     : num [1:10208] 35 20 30 40 48 44 40 20 54 35 ...
 $ ingreso_ocup      : num [1:10208] 1200 500 430 1000 1000 900 700 353 700 900 ...
 $ ingreso_hogar     : num [1:10208] 1200 2700 930 4000 4000 ...
 $ ingreso_per_capita: num [1:10208] 300 900 465 1000 1000 320 320 431 431 300 ...
```

Excluimos `ingreso_hogar` e `ingreso_per_capita` como predictoras porque se derivan del ingreso de la ocupación principal (variable respuesta). La variable `ant_laboral` presenta 1033 valores faltantes, por lo que trabajamos con observaciones completas.

```
datos_modelo <- datos %>%
  select(ingreso_ocup, sexo, edad, est_civil, region, educ_cat,
         ant_laboral, formal, horas_trabajo) %>%
  na.omit()
```

1.2. Partición train/test (70/30)

```r
set.seed(2026)
n <- nrow(datos_modelo)
idx_train <- sample(seq_len(n), size = floor(0.70 * n))

train <- datos_modelo[idx_train, ]
test  <- datos_modelo[-idx_train, ]

cat("Train:", nrow(train), "| Test:", nrow(test))
```

```
Train: 6422 | Test: 2753
```

1.3. Ajuste de tres modelos de RLM por MCO

Proponemos tres modelos con distintas estrategias:

- **M1 (Criterio propio):** variables que por conocimiento del problema deberían asociarse al ingreso: sexo, edad, educación, formalidad y horas trabajadas.
- **M2 (Forward Selection por AIC):** partiendo de un modelo nulo, se incorporan predictores de a uno minimizando el AIC.
- **M3 (Modelo completo):** incluye todos los predictores disponibles.

```r
# M1: Criterio propio
M1 <- lm(ingreso_ocup ~ sexo + edad + educ_cat + formal + horas_trabajo, data = train)

# M2: Forward Selection
modelo_nulo   <- lm(ingreso_ocup ~ 1, data = train)
modelo_maximo <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
                      ant_laboral + formal + horas_trabajo, data = train)

M2 <- stepAIC(modelo_nulo,
              scope = list(upper = modelo_maximo),
              direction = "forward", trace = FALSE)

# M3: Completo
M3 <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
            ant_laboral + formal + horas_trabajo, data = train)
```

1.4. Comparación de modelos: CME, PRESS, AIC y BIC

```r
metricas <- function(modelo, nombre) {
  n <- length(residuals(modelo))
  p <- length(coefficients(modelo))
  cme <- deviance(modelo) / (n - p)
  press <- sum((residuals(modelo) / (1 - hatvalues(modelo)))^2)
```

```r
  data.frame(Modelo = nombre, CME = round(cme, 2), PRESS = round(press, 0),
             AIC = round(AIC(modelo), 2), BIC = round(BIC(modelo), 2))
}

comparacion <- rbind(
  metricas(M1, "M1 - Criterio propio"),
  metricas(M2, "M2 - Forward AIC"),
  metricas(M3, "M3 - Completo")
)
kable(comparacion, row.names = FALSE)
```

Modelo	CME	PRESS	AIC	BIC
M1 - Criterio propio	340710.0	2190937327	100043.33	100104.2
M2 - Forward AIC	311183.1	2004430370	99475.14	99630.8
M3 - Completo	311183.1	2004430370	99475.14	99630.8

Buscamos el menor valor en todas las métricas. El modelo M2 (Forward) logra un buen balance entre ajuste y parsimonia. **Elegimos M2 como modelo ganador.**

```r
cat("Variables incluidas en M2:\n")
```

```
Variables incluidas en M2:
```

```r
names(coef(M2))
```

```
 [1] "(Intercept)"                    "formalSi"
 [3] "horas_trabajo"                  "regionGran Buenos Aires"
 [5] "regionNoreste"                  "regionNoroeste"
 [7] "regionPampeana"                 "regionPatagonia"
 [9] "educ_catPrimario"               "educ_catSecundario"
[11] "educ_catSuperior"               "edad"
[13] "sexoMujer"                      "est_civilseparado o divorciado"
[15] "est_civilsoltero"               "est_civilunido"
[17] "est_civilviudo"                 "ant_laboral1 a 3 meses"
[19] "ant_laboralEntre 3 y 6 meses"   "ant_laboral6 meses a 1 año"
[21] "ant_laboral1 a 5 años"          "ant_laboralMas de 5 años"
```

1.5. Análisis de residuos

1.5.1. Linealidad y homocedasticidad

```r
par(mfrow = c(1, 2))
plot(M2, which = 1, main = "Residuos vs Ajustados")
plot(M2, which = 3, main = "Scale-Location")
```

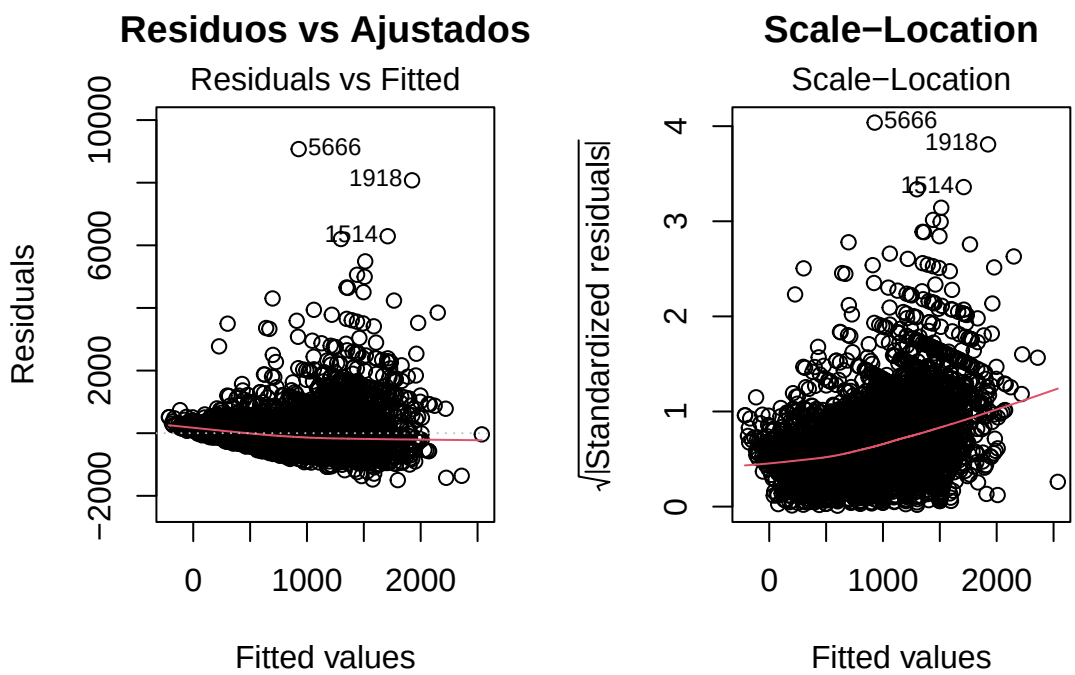


```r
bptest(M2)
```

```
    studentized Breusch-Pagan test

data:  M2
BP = 122.95, df = 21, p-value < 2.2e-16
```

1.5.2. Normalidad de los residuos

```r
plot(M2, which = 2, main = "QQ-Plot")
```

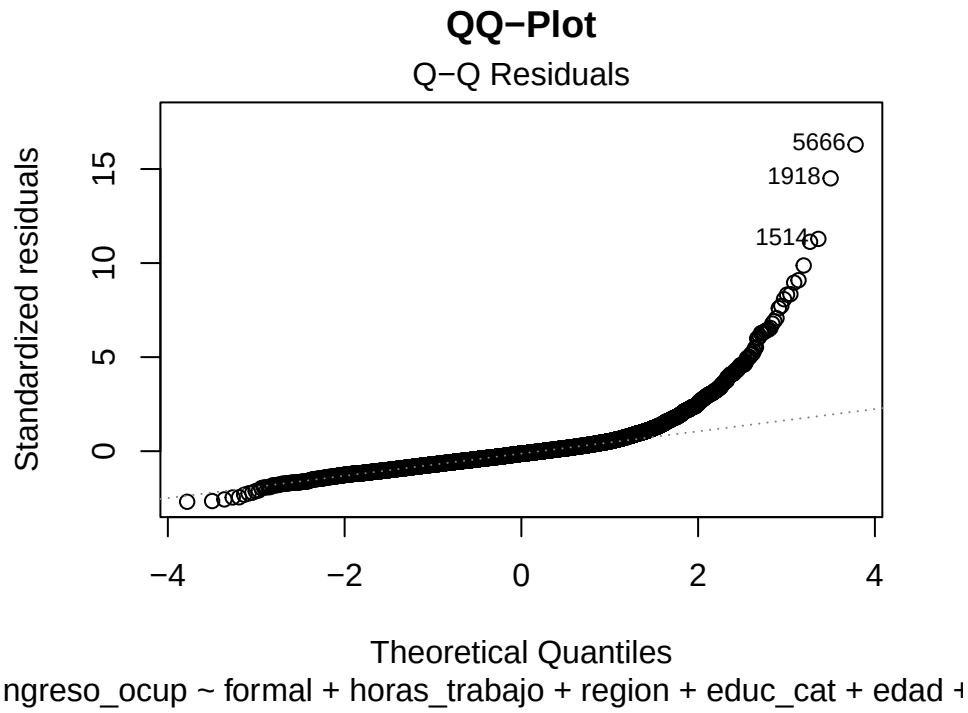


```r
set.seed(123)
shapiro.test(sample(residuals(M2), min(5000, length(residuals(M2)))))
```

```
    Shapiro-Wilk normality test

data:  sample(residuals(M2), min(5000, length(residuals(M2))))
W = 0.75281, p-value < 2.2e-16
```

1.5.3. Independencia

```r
dwtest(M2)
```

```
    Durbin-Watson test

data:  M2
DW = 2.0232, p-value = 0.8238
alternative hypothesis: true autocorrelation is greater than 0
```

1.5.4. Colinealidad (VIF)

```r
vif(M2)
```

```
                   GVIF Df GVIF^(1/(2*Df))
formal         1.409807  1        1.187353
horas_trabajo  1.099170  1        1.048413
region         1.083692  5        1.008070
educ_cat       1.286159  3        1.042835
edad           1.685184  1        1.298146
sexo           1.178412  1        1.085547
est_civil      1.474017  4        1.049694
ant_laboral    1.566682  5        1.045919
```

Para variables categóricas, se reporta el GVIF. Valores de $GVIF^{1/(2 \cdot Df)}$ superiores a 2.24 ($\approx \sqrt{5}$) sugieren problemas de colinealidad.

1.5.5. Observaciones atípicas e influyentes

```r
par(mfrow = c(1, 2))
plot(M2, which = 4, main = "Distancia de Cook")
plot(M2, which = 5, main = "Leverage vs Residuos")
```

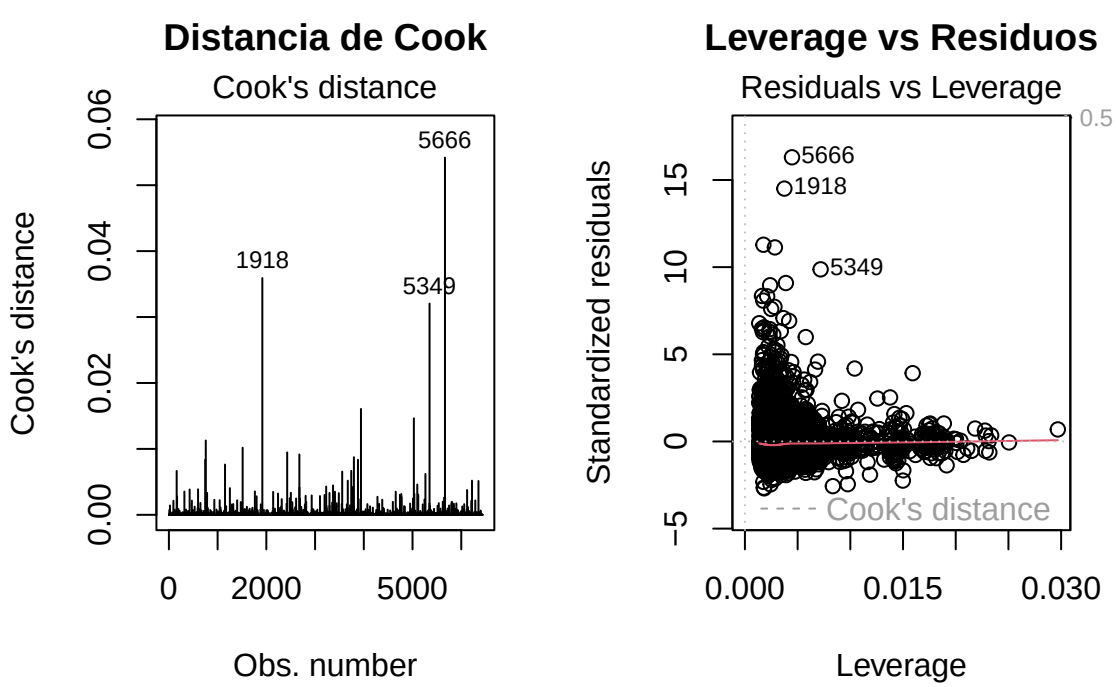

```r
umbral_cook <- 4 / nrow(train)
cat("Umbral Cook (4/n):", round(umbral_cook, 6), "\n")
```

```
Umbral Cook (4/n): 0.000623
```

```r
cat("Obs. influyentes:", sum(cooks.distance(M2) > umbral_cook))
```

```
Obs. influyentes: 220
```

1.6. Interpretación de coeficientes

```r
summary(M2)
```

```
Call:
lm(formula = ingreso_ocup ~ formal + horas_trabajo + region +
    educ_cat + edad + sexo + est_civil + ant_laboral, data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-1498.7  -292.9   -74.0   151.3  9073.0

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                    -156.3916    94.8151  -1.649 0.099107 .
formalSi                        326.2601    17.8508  18.277  < 2e-16 ***
horas_trabajo                    10.6605     0.4847  21.994  < 2e-16 ***
regionGran Buenos Aires         132.4558    29.2710   4.525 6.14e-06 ***
regionNoreste                  -132.0093    33.9841  -3.884 0.000104 ***
regionNoroeste                 -139.3807    26.0190  -5.357 8.76e-08 ***
regionPampeana                   94.2209    25.6160   3.678 0.000237 ***
regionPatagonia                 376.3633    29.7081  12.669  < 2e-16 ***
educ_catPrimario                 43.4510    51.5338   0.843 0.399173
educ_catSecundario              170.5507    50.8827   3.352 0.000807 ***
educ_catSuperior                502.9233    52.1128   9.651  < 2e-16 ***
edad                              4.1317     0.7425   5.565 2.73e-08 ***
sexoMujer                      -144.6162    15.3694  -9.409  < 2e-16 ***
est_civilseparado o divorciado -111.3200    28.8668  -3.856 0.000116 ***
est_civilsoltero               -118.1565    21.0940  -5.601 2.21e-08 ***
est_civilunido                  -44.3525    20.1793  -2.198 0.027991 *
est_civilviudo                 -178.3733    65.1660  -2.737 0.006213 **
ant_laboral1 a 3 meses          168.9406    78.0586   2.164 0.030480 *
ant_laboralEntre 3 y 6 meses    127.2104    78.4437   1.622 0.104922
ant_laboral6 meses a 1 año       93.6701    76.8113   1.219 0.222706
```

```
ant_laboral1 a 5 años           148.4032    71.3995   2.078 0.037704 *
ant_laboralMas de 5 años        224.0193    71.9585   3.113 0.001859 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 557.8 on 6400 degrees of freedom
Multiple R-squared:  0.3455,    Adjusted R-squared:  0.3434
F-statistic: 160.9 on 21 and 6400 DF,  p-value: < 2.2e-16
```

```r
kable(round(confint(M2), 4), col.names = c("IC 2.5%", "IC 97.5%"))
```

	IC 2.5%	IC 97.5%
(Intercept)	-342.2609	29.4776
formalSi	291.2665	361.2537
horas_trabajo	9.7103	11.6107
regionGran Buenos Aires	75.0749	189.8367
regionNoreste	-198.6295	-65.3892
regionNoroeste	-190.3867	-88.3748
regionPampeana	44.0049	144.4368
regionPatagonia	318.1254	434.6011
educ_catPrimario	-57.5725	144.4746
educ_catSecundario	70.8035	270.2978
educ_catSuperior	400.7648	605.0817
edad	2.6762	5.5872
sexoMujer	-174.7453	-114.4871
est_civilseparado o divorciado	-167.9085	-54.7314
est_civilsoltero	-159.5078	-76.8052
est_civilunido	-83.9108	-4.7942
est_civilviudo	-306.1205	-50.6262
ant_laboral1 a 3 meses	15.9195	321.9616
ant_laboralEntre 3 y 6 meses	-26.5655	280.9863
ant_laboral6 meses a 1 año	-56.9058	244.2460
ant_laboral1 a 5 años	8.4362	288.3701
ant_laboralMas de 5 años	82.9565	365.0821

Interpretación: cada coeficiente representa el cambio esperado en el ingreso por ocupación principal (en miles de pesos) ante un cambio unitario del predictor, manteniendo las demás variables constantes. Los p-valores del test t indican la significación estadística de cada efecto. Se destacan: la brecha salarial por sexo, el efecto positivo de la educación y la formalidad, y la relación directa entre horas trabajadas e ingreso.

2. Consigna II: Regularización y Predicción

2.1. Preparación de datos para glmnet

```
X_train <- model.matrix(M2, data = train)[, -1]
y_train <- train$ingreso_ocup

X_test <- model.matrix(M2, data = test)[, -1]
y_test <- test$ingreso_ocup
```

2.2. Ajuste Ridge

```
set.seed(2026)
cv_ridge <- cv.glmnet(x = X_train, y = y_train, alpha = 0, nfolds = 10)
plot(cv_ridge, main = "CV Ridge")
```

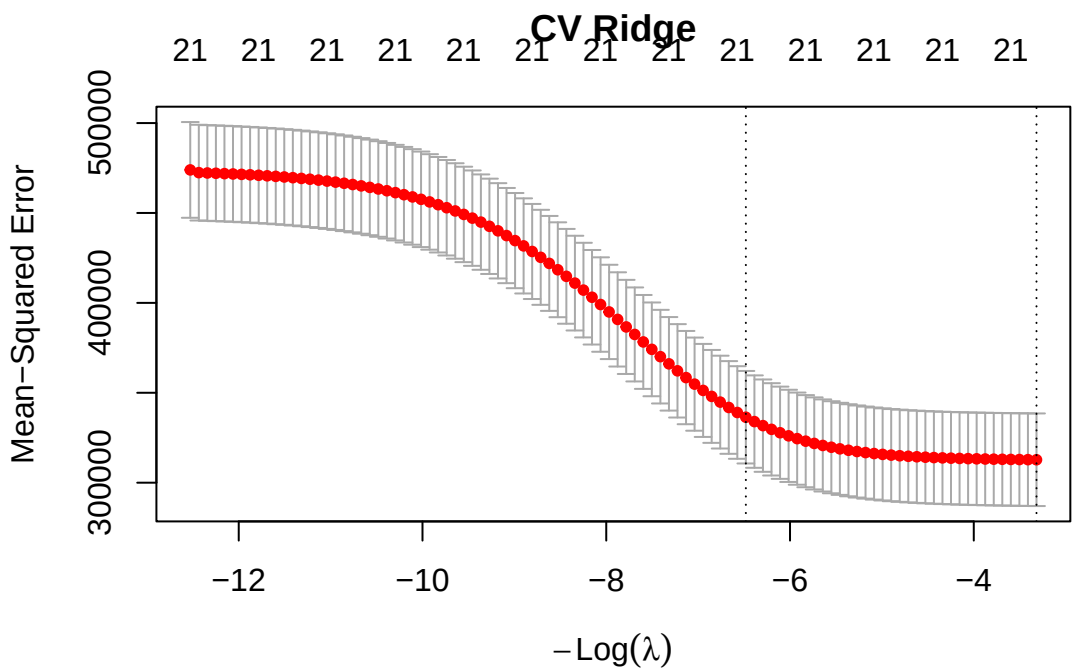


```
cat("Lambda óptimo Ridge:", cv_ridge$lambda.min)
```

```
Lambda óptimo Ridge: 27.58713
```

```r
m_ridge <- glmnet(x = X_train, y = y_train, alpha = 0, lambda = cv_ridge$lambda.min)

comp_ridge <- data.frame(
  MCO   = round(coef(M2), 4),
  Ridge = round(as.vector(coef(m_ridge)), 4)
)
kable(comp_ridge)
```

	MCO	Ridge
(Intercept)	-156.3916	120.3910
formalSi	326.2601	325.0741
horas_trabajo	10.6605	10.3053
regionGran Buenos Aires	132.4558	115.9544
regionNoreste	-132.0093	-137.4698
regionNoroeste	-139.3807	-148.3879
regionPampeana	94.2209	77.1823
regionPatagonia	376.3633	353.8742
educ_catPrimario	43.4510	-86.3102
educ_catSecundario	170.5507	37.0115
educ_catSuperior	502.9233	357.8937
edad	4.1317	4.0018
sexoMujer	-144.6162	-135.8488
est_civilseparado o divorciado	-111.3200	-102.1878
est_civilsoltero	-118.1565	-109.9952
est_civilunido	-44.3525	-37.6294
est_civilviudo	-178.3733	-179.7710
ant_laboral1 a 3 meses	168.9406	39.3699
ant_laboralEntre 3 y 6 meses	127.2104	0.7694
ant_laboral6 meses a 1 año	93.6701	-29.0308
ant_laboral1 a 5 años	148.4032	24.7063
ant_laboralMas de 5 años	224.0193	104.1177

Los coeficientes Ridge son levemente menores en valor absoluto que los de MCO, como es esperable dada la penalización cuadrática que encoge las estimaciones hacia cero.

2.3. Ajuste Lasso

```r
set.seed(2026)
cv_lasso <- cv.glmnet(x = X_train, y = y_train, alpha = 1, nfolds = 10)
plot(cv_lasso, main = "CV Lasso")
```

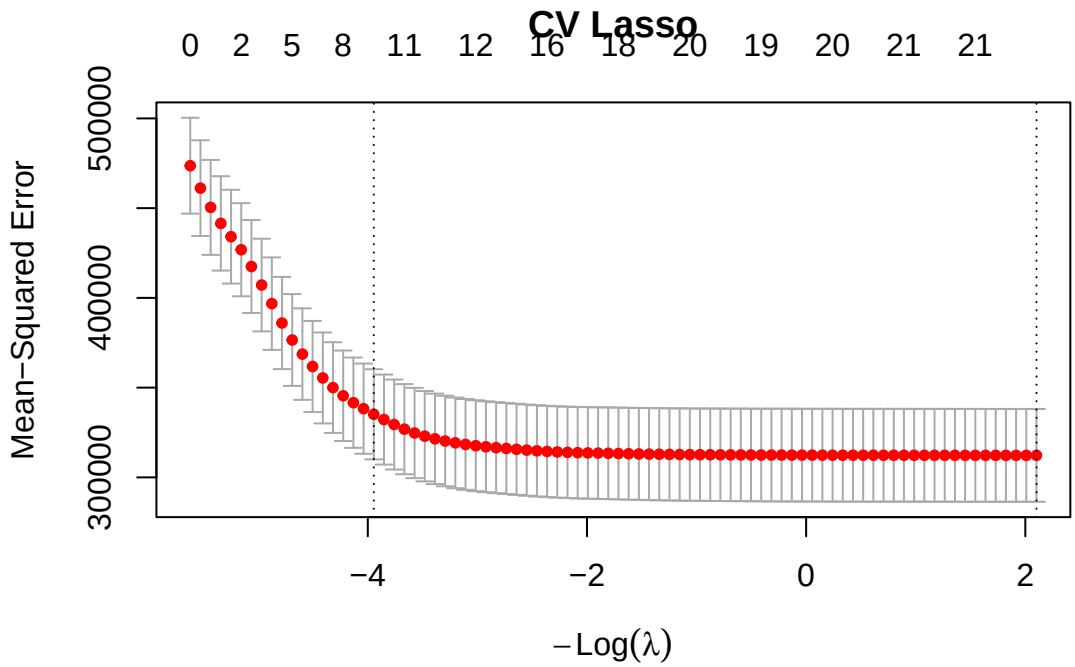


```r
cat("Lambda óptimo Lasso:", cv_lasso$lambda.min)
```

```
Lambda óptimo Lasso: 0.1222281
```

```r
m_lasso <- glmnet(x = X_train, y = y_train, alpha = 1, lambda = cv_lasso$lambda.min)

comp_lasso <- data.frame(
  MCO   = round(coef(M2), 4),
  Lasso = round(as.vector(coef(m_lasso)), 4)
)
kable(comp_lasso)
```

	MCO	Lasso
(Intercept)	-156.3916	-115.8483
formalSi	326.2601	327.0270
horas_trabajo	10.6605	10.6608
regionGran Buenos Aires	132.4558	131.3488
regionNoreste	-132.0093	-132.1485
regionNoroeste	-139.3807	-139.6848
regionPampeana	94.2209	93.0376
regionPatagonia	376.3633	375.5515
educ_catPrimario	43.4510	33.6935
educ_catSecundario	170.5507	160.9229

	MCO	Lasso
educ_catSuperior	502.9233	493.3473
edad	4.1317	4.1184
sexoMujer	-144.6162	-144.1634
est_civilseparado o divorciado	-111.3200	-110.1913
est_civilsoltero	-118.1565	-117.2072
est_civilunido	-44.3525	-43.4651
est_civilviudo	-178.3733	-177.4155
ant_laboral1 a 3 meses	168.9406	136.6847
ant_laboralEntre 3 y 6 meses	127.2104	94.9721
ant_laboral6 meses a 1 año	93.6701	61.5366
ant_laboral1 a 5 años	148.4032	116.6234
ant_laboralMas de 5 años	224.0193	192.6245

Lasso puede llevar coeficientes exactamente a cero, realizando simultáneamente estimación y selección de variables.

2.4. Evaluación predictiva en datos de prueba

```
pred_mco   <- predict(M2, newdata = test)
pred_ridge <- as.vector(predict(m_ridge, newx = X_test, s = cv_ridge$lambda.min))
pred_lasso <- as.vector(predict(m_lasso, newx = X_test, s = cv_lasso$lambda.min))

sct_test <- sum((y_test - mean(y_test))^2)

resultados <- data.frame(
  Modelo  = c("MCO", "Ridge", "Lasso"),
  MSE     = round(c(mean((y_test - pred_mco)^2),
                    mean((y_test - pred_ridge)^2),
                    mean((y_test - pred_lasso)^2)), 2),
  RMSE    = round(c(sqrt(mean((y_test - pred_mco)^2)),
                    sqrt(mean((y_test - pred_ridge)^2)),
                    sqrt(mean((y_test - pred_lasso)^2))), 2),
  R2_Pred = round(c(1 - sum((y_test - pred_mco)^2) / sct_test,
                    1 - sum((y_test - pred_ridge)^2) / sct_test,
                    1 - sum((y_test - pred_lasso)^2) / sct_test), 4)
)
kable(resultados)
```

Modelo	MSE	RMSE	R2_Pred
MCO	377387.4	614.32	0.3000
Ridge	378422.0	615.16	0.2981
Lasso	377427.3	614.35	0.2999

El modelo con menor MSE y mayor R^2 de predicción es el más adecuado. En este caso, dado que la colinealidad no es severa y $n >> p$, los tres métodos arrojan resultados similares.

3. Consigna III: Regresión Logística

3.1. Definición de la variable respuesta binaria

```
datos_logit <- datos_modelo %>%
  mutate(Y = ifelse(ingreso_ocup >= 1000, 1, 0))

table(datos_logit$Y)
```

```
   0    1
5655 3520
```

```
cat("Proporción Y=1:", round(mean(datos_logit$Y), 4))
```

```
Proporción Y=1: 0.3837
```

3.2. Partición train/test con createDataPartition

```
set.seed(2026)
idx_logit <- createDataPartition(datos_logit$Y, p = 0.70, list = FALSE)

train_logit <- datos_logit[idx_logit, ]
test_logit  <- datos_logit[-idx_logit, ]

cat("Train:", nrow(train_logit), "| Test:", nrow(test_logit), "\n")
```

```
Train: 6423 | Test: 2752
```

```
cat("Prop Y=1 Train:", round(mean(train_logit$Y), 4), "\n")
```

```
Prop Y=1 Train: 0.3875
```

```
cat("Prop Y=1 Test: ", round(mean(test_logit$Y), 4))
```

```
Prop Y=1 Test:  0.3746
```

Se verifica que `createDataPartition()` mantiene la proporción de éxitos balanceada.

3.3. Ajuste del modelo de regresión logística

Usamos las mismas variables explicativas que el modelo ganador M2.

```r
vars_m2 <- attr(terms(M2), "term.labels")
formula_logit <- as.formula(paste("Y ~", paste(vars_m2, collapse = " + ")))

MLog <- glm(formula_logit, data = train_logit, family = binomial(link = "logit"))
summary(MLog)
```

```
Call:
glm(formula = formula_logit, family = binomial(link = "logit"),
    data = train_logit)

Coefficients:
                                Estimate Std. Error z value Pr(>|z|)
(Intercept)                    -6.115474   0.605726 -10.096  < 2e-16 ***
formalSi                        1.699769   0.094614  17.965  < 2e-16 ***
horas_trabajo                   0.047273   0.002591  18.242  < 2e-16 ***
regionGran Buenos Aires         0.583426   0.132034   4.419 9.93e-06 ***
regionNoreste                  -0.614444   0.156353  -3.930 8.50e-05 ***
regionNoroeste                 -0.822909   0.125612  -6.551 5.71e-11 ***
regionPampeana                  0.480778   0.117733   4.084 4.43e-05 ***
regionPatagonia                 1.691959   0.137985  12.262  < 2e-16 ***
educ_catPrimario                0.349678   0.276905   1.263  0.20666
educ_catSecundario              1.142179   0.271940   4.200 2.67e-05 ***
educ_catSuperior                2.171311   0.276574   7.851 4.14e-15 ***
edad                            0.020326   0.003476   5.848 4.98e-09 ***
sexoMujer                      -0.747876   0.071978 -10.390  < 2e-16 ***
est_civilseparado o divorciado -0.548787   0.128838  -4.260 2.05e-05 ***
est_civilsoltero               -0.493374   0.093956  -5.251 1.51e-07 ***
est_civilunido                 -0.078270   0.088560  -0.884  0.37680
est_civilviudo                 -0.868035   0.320662  -2.707  0.00679 **
ant_laboral1 a 3 meses          0.348796   0.530779   0.657  0.51109
ant_laboralEntre 3 y 6 meses   -0.019585   0.531000  -0.037  0.97058
ant_laboral6 meses a 1 año      0.205583   0.515871   0.399  0.69025
ant_laboral1 a 5 años           0.577752   0.490281   1.178  0.23863
ant_laboralMas de 5 años        0.924854   0.490478   1.886  0.05935 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 8576.3  on 6422  degrees of freedom
Residual deviance: 5898.3  on 6401  degrees of freedom
AIC: 5942.3
```

```
Number of Fisher Scoring iterations: 5
```

3.3.1. Razones de odds (OR) para predictores significativos al 5 %

```r
coefs <- summary(MLog)$coefficients
significativos <- coefs[coefs[, 4] < 0.05, , drop = FALSE]

or_tabla <- data.frame(
  OR       = round(exp(significativos[, 1]), 4),
  IC_lower = round(exp(significativos[, 1] - 1.96 * significativos[, 2]), 4),
  IC_upper = round(exp(significativos[, 1] + 1.96 * significativos[, 2]), 4),
  p_valor  = round(significativos[, 4], 6)
)
kable(or_tabla, col.names = c("OR", "IC 2.5%", "IC 97.5%", "p-valor"))
```

	OR	IC 2.5 %	IC 97.5 %	p-valor
(Intercept)	0.0022	0.0007	0.0072	0.000000
formalSi	5.4727	4.5464	6.5878	0.000000
horas_trabajo	1.0484	1.0431	1.0537	0.000000
regionGran Buenos Aires	1.7922	1.3835	2.3215	0.000010
regionNoreste	0.5409	0.3982	0.7349	0.000085
regionNoroeste	0.4392	0.3433	0.5617	0.000000
regionPampeana	1.6173	1.2841	2.0371	0.000044
regionPatagonia	5.4301	4.1434	7.1165	0.000000
educ_catSecundario	3.1336	1.8389	5.3398	0.000027
educ_catSuperior	8.7698	5.0999	15.0804	0.000000
edad	1.0205	1.0136	1.0275	0.000000
sexoMujer	0.4734	0.4111	0.5451	0.000000
est_civilseparado o divorciado	0.5777	0.4487	0.7436	0.000020
est_civilsoltero	0.6106	0.5079	0.7340	0.000000
est_civilviudo	0.4198	0.2239	0.7870	0.006789

Un OR > 1 indica que ese predictor aumenta las chances de percibir un ingreso ≥ 1000 mil pesos; un OR < 1 las disminuye, manteniendo las demás variables constantes.

3.4. Punto de corte óptimo (Curva ROC)

```r
curvaROC <- roc(response = train_logit$Y,
                predictor = fitted.values(MLog), quiet = TRUE)

plot(curvaROC, print.auc = TRUE, print.thres = TRUE)
```

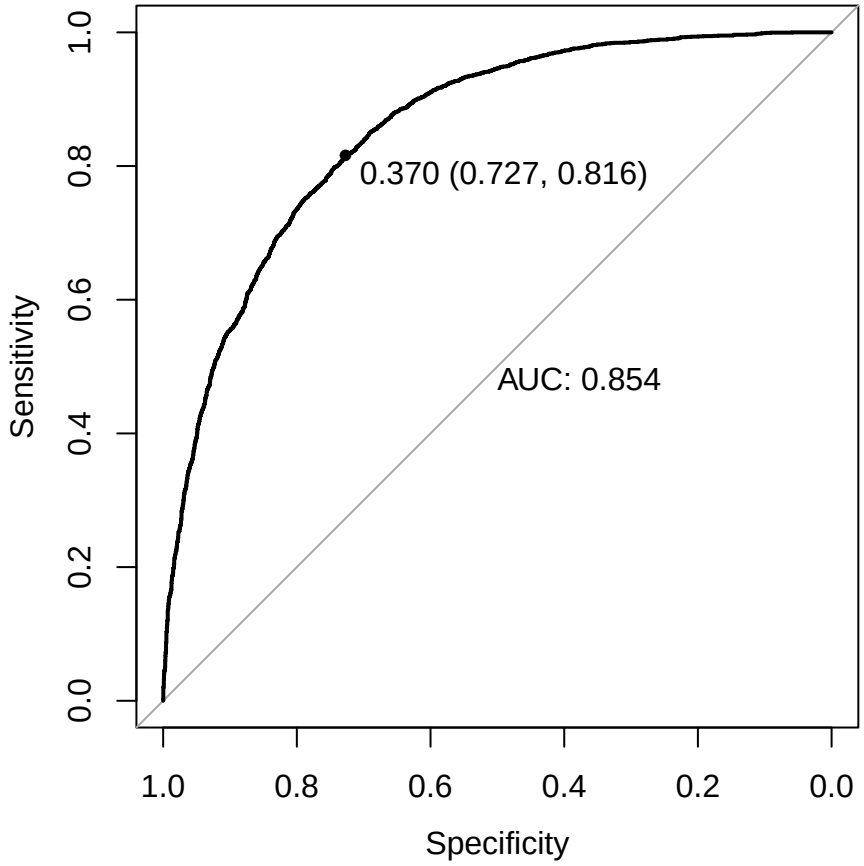


```
corte_optimo <- coords(curvaROC, "best", ret = "threshold")$threshold
cat("Punto de corte óptimo:", corte_optimo, "\n")
```

```
Punto de corte óptimo: 0.369624
```

```
cat("AUC:", as.numeric(auc(curvaROC)))
```

```
AUC: 0.8540701
```

3.5. Clasificación y Matriz de Confusión en datos de prueba

```
prob_test  <- predict(MLog, newdata = test_logit, type = "response")
pred_clase <- factor(ifelse(prob_test >= corte_optimo, 1, 0), levels = c("0","1"))
real_clase <- factor(test_logit$Y, levels = c("0","1"))

mc <- confusionMatrix(pred_clase, real_clase, positive = "1")
mc
```

```
Confusion Matrix and Statistics

          Reference
Prediction    0    1
         0 1215  217
         1  506  814

               Accuracy : 0.7373
                 95% CI : (0.7204, 0.7536)
    No Information Rate : 0.6254
    P-Value [Acc > NIR] : < 2.2e-16

                  Kappa : 0.4691

 Mcnemar's Test P-Value : < 2.2e-16

            Sensitivity : 0.7895
            Specificity : 0.7060
         Pos Pred Value : 0.6167
         Neg Pred Value : 0.8485
             Prevalence : 0.3746
         Detection Rate : 0.2958
   Detection Prevalence : 0.4797
      Balanced Accuracy : 0.7478

       'Positive' Class : 1
```

3.5.1. Métricas de clasificación

```r
metricas_clas <- data.frame(
  Metrica = c("Precisión (Accuracy)", "Sensibilidad", "Especificidad", "VPP", "VPN"),
  Valor   = round(c(mc$overall["Accuracy"],
                    mc$byClass["Sensitivity"],
                    mc$byClass["Specificity"],
                    mc$byClass["Pos Pred Value"],
                    mc$byClass["Neg Pred Value"]), 4)
)
kable(metricas_clas, row.names = FALSE)
```

Metrica	Valor
Precisión (Accuracy)	0.7373
Sensibilidad	0.7895
Especificidad	0.7060
VPP	0.6167

Metrica	Valor
VPN	0.8485

Interpretación:

- **Precisión:** proporción total de individuos correctamente clasificados.
- **Sensibilidad:** proporción de individuos con ingreso ≥ 1000 correctamente identificados como tales.
- **Especificidad:** proporción de individuos con ingreso < 1000 correctamente identificados como tales.
- **VPP:** cuando el modelo predice Y=1, proporción de veces que acierta.
- **VPN:** cuando el modelo predice Y=0, proporción de veces que acierta.