Trabajo Práctico Final

Regresión Avanzada
Maestría en Explotación de Datos y Gestión del Conocimiento
Universidad Austral

Juan Ignacio Cacchione Mariangeles Alomar

Invalid Date

Tabla de contenidos

1 Consigna I: Regresión Lineal **2**
1.1 Carga de datos . . . 2
1.2 Partición train/test (70/30) . . . 2
1.3 Ajuste de tres modelos de RLM por MCO . . . 2
1.4 Comparación: CME, PRESS, AIC y BIC . . . 3
1.5 Análisis de residuos . . . 4
1.5.1 Linealidad y homocedasticidad . . . 4
1.5.2 Normalidad . . . 5
1.5.3 Independencia . . . 5
1.5.4 Colinealidad (VIF) . . . 6
1.5.5 Casos atípicos e influyentes . . . 6
1.6 Interpretación de coeficientes . . . 7

2 Consigna II: Regularización y Predicción **10**
2.1 Preparación de datos . . . 10
2.2 Ajuste Ridge . . . 10
2.3 Ajuste Lasso . . . 11
2.4 Evaluación predictiva (datos de prueba) . . . 13

3 Consigna III: Regresión Logística **14**
3.1 Definición de la variable respuesta . . . 14
3.2 Partición con createDataPartition . . . 14
3.3 Modelo de regresión logística . . . 14
3.3.1 Razones de odds (predictores significativos al 5 %, test de Wald) . . . 15
3.4 Punto de corte óptimo (Curva ROC) . . . 16
3.5 Clasificación y Matriz de Confusión (datos de prueba) . . . 17
3.5.1 Métricas de clasificación . . . 17

1. Consigna I: Regresión Lineal

1.1. Carga de datos

```
datos <- read_excel("eph.xlsx")

# Convertimos a factor y recodificamos NA de ant_laboral como "Desconocido"
datos <- datos %>%
  mutate(
    sexo = factor(sexo),
    est_civil = factor(est_civil),
    region = factor(region),
    educ_cat = factor(educ_cat, levels = c("Ninguno","Primario","Secundario","Superior")),
    formal = factor(formal),
    ant_laboral = factor(
      ifelse(is.na(ant_laboral), "Desconocido", ant_laboral),
      levels = c("Mas de 5 años","1 a 5 años","6 meses a 1 año",
                 "Entre 3 y 6 meses","1 a 3 meses","Menos de 1 mes","Desconocido"))
  )

# Seleccionamos predictoras (excluimos ingreso_hogar e ingreso_per_capita)
datos_modelo <- datos %>%
  select(ingreso_ocup, sexo, edad, est_civil, region, educ_cat,
         ant_laboral, formal, horas_trabajo)
```

Se excluyen `ingreso_hogar` e `ingreso_per_capita` para evitar problemas de endogeneidad: el ingreso total del hogar es *consecuencia* del ingreso por ocupación principal, no su causa. Incluirlas generaría relaciones espurias. Los 1033 valores faltantes de `ant_laboral` se recodificaron como categoría "Desconocido" para conservar las 10208 observaciones.

1.2. Partición train/test (70/30)

```
set.seed(2026)
idx_train <- sample(seq_len(nrow(datos_modelo)), size = floor(0.70 * nrow(datos_modelo)))
train <- datos_modelo[idx_train, ]
test  <- datos_modelo[-idx_train, ]
```

Train: 7145 observaciones | Test: 3063 observaciones.

1.3. Ajuste de tres modelos de RLM por MCO

Se proponen tres modelos con distintas estrategias de selección:

- **M1 (criterio propio):** incluimos las variables que, por conocimiento del mercado laboral, deberían asociarse al ingreso: sexo, edad, educación, formalidad, horas trabajadas y región (la desigualdad territorial de ingresos en Argentina está ampliamente documentada).
- **M2 (stepwise por AIC):** selección bidireccional que puede incorporar y eliminar variables en cada paso.
- **M3 (modelo completo):** todas las predictoras disponibles.

```r
# M1: Criterio propio
M1 <- lm(ingreso_ocup ~ sexo + edad + educ_cat + formal + horas_trabajo + region,
          data = train)

# M2: Stepwise bidireccional
m_nulo   <- lm(ingreso_ocup ~ 1, data = train)
m_maximo <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
                 ant_laboral + formal + horas_trabajo, data = train)

M2 <- stepAIC(m_nulo,
              scope = list(lower = m_nulo, upper = m_maximo),
              direction = "both", trace = FALSE, k = 2)

# M3: Completo
M3 <- lm(ingreso_ocup ~ sexo + edad + est_civil + region + educ_cat +
            ant_laboral + formal + horas_trabajo, data = train)
```

1.4. Comparación: CME, PRESS, AIC y BIC

Modelo	CME	PRESS	AIC	BIC
M1 - Criterio propio	313398.6	2243745745	110713.2	110809.5
M2 - Stepwise AIC	308079.8	2207824918	110600.9	110765.9
M3 - Completo	308079.8	2207824918	110600.9	110765.9

El modelo con menores valores de CME, PRESS, AIC y BIC es **M2 - Stepwise AIC**. Lo elegimos como modelo ganador. Las variables incluidas son: formal, horas_trabajo, educ_cat, region, ant_laboral, sexo, est_civil, edad.

1.5. Análisis de residuos

1.5.1. Linealidad y homocedasticidad

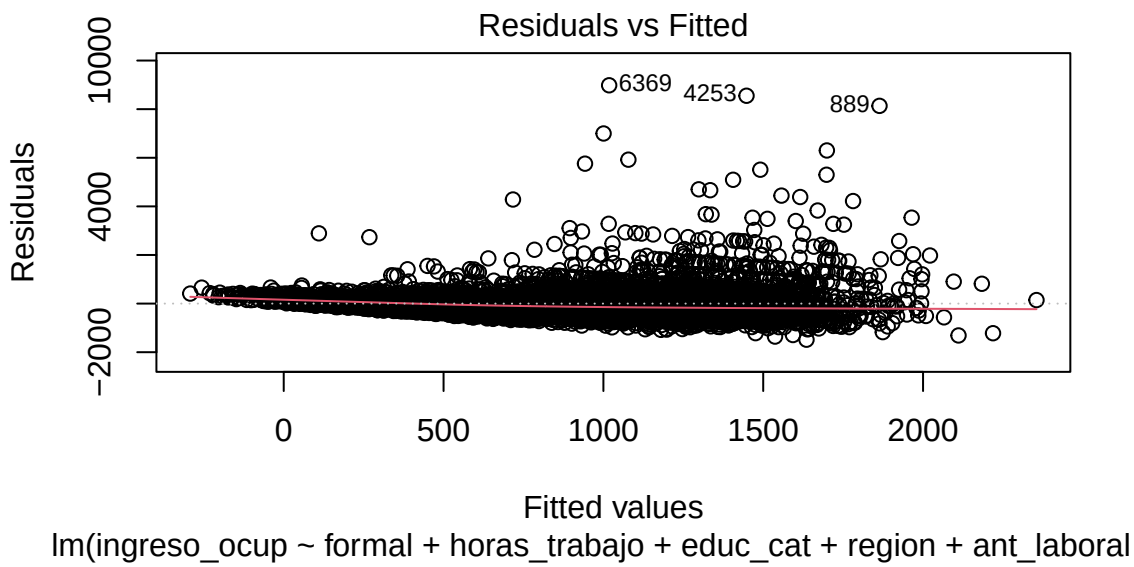

Se observa que los residuos no se distribuyen de manera perfectamente uniforme. Para confirmarlo, aplicamos el test de Breusch-Pagan:

H_0) Variancia constante
H_1) Variancia no constante

```r
bptest(M2)
```

```
    studentized Breusch-Pagan test

data:  M2
BP = 147.81, df = 22, p-value < 2.2e-16
```

El p-valor (<2e-16) es menor al 5 %, por lo que se rechaza H_0. Esto indica presencia de heterocedasticidad. Sin embargo, dado el gran tamaño muestral ($n > 7.145$), las inferencias sobre los coeficientes se mantienen válidas por aplicación del Teorema Central del Límite (TCL).

1.5.2. Normalidad

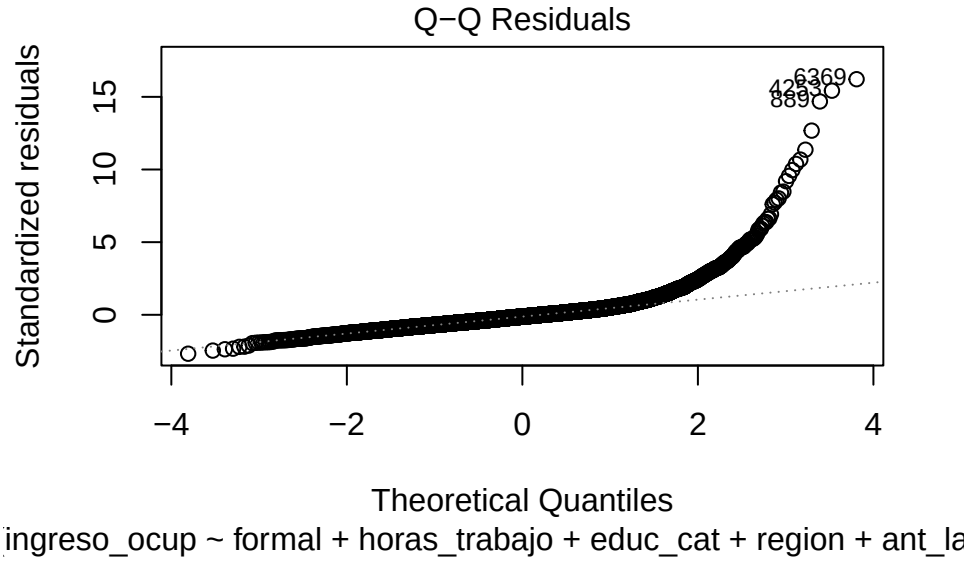

En el QQ-Plot se observa que las colas se desvían de la recta teórica. Aplicamos el test de Anderson-Darling:

H_0) Los residuos siguen una distribución Normal
H_1) Los residuos no siguen una distribución Normal

```
ad.test(residuals(M2))
```

```
    Anderson-Darling normality test

data:  residuals(M2)
A = 329.65, p-value < 2.2e-16
```

El p-valor (<2e-16) es menor al 5 %, por lo que se rechaza H_0. Nuevamente, por aplicación del TCL con $n > 7.145$, las inferencias sobre los coeficientes se mantienen válidas pese a la desviación del supuesto de normalidad.

1.5.3. Independencia

```
dwtest(M2)
```

```
    Durbin-Watson test

data:  M2
DW = 2.0058, p-value = 0.5972
alternative hypothesis: true autocorrelation is greater than 0
```

El estadístico de Durbin-Watson es 2.0058. Dado que los datos provienen de una encuesta y no de una serie temporal, este test debe interpretarse con cautela.

1.5.4. Colinealidad (VIF)

```r
vif(M2)
```

```
                  GVIF Df GVIF^(1/(2*Df))
formal        1.514232  1        1.230541
horas_trabajo 1.178292  1        1.085491
educ_cat      1.306681  3        1.045590
region        1.069094  5        1.006704
ant_laboral   2.046311  6        1.061486
sexo          1.313161  1        1.145933
est_civil     1.446218  4        1.047199
edad          1.621714  1        1.273465
```

Para variables categóricas se reporta el GVIF (Generalized VIF) ajustado por grados de libertad. Valores de $GVIF^{1/(2 \cdot Df)}$ superiores a $\sqrt{5} \approx 2.24$ sugieren problemas de colinealidad. En nuestro caso, todos los valores están por debajo de este umbral: **no se detecta colinealidad**.

1.5.5. Casos atípicos e influyentes

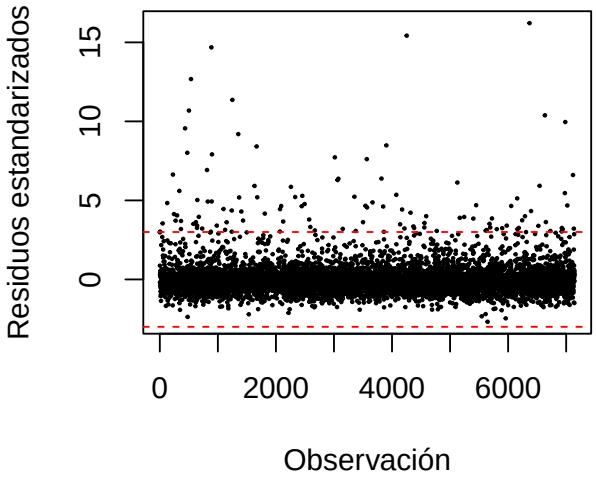

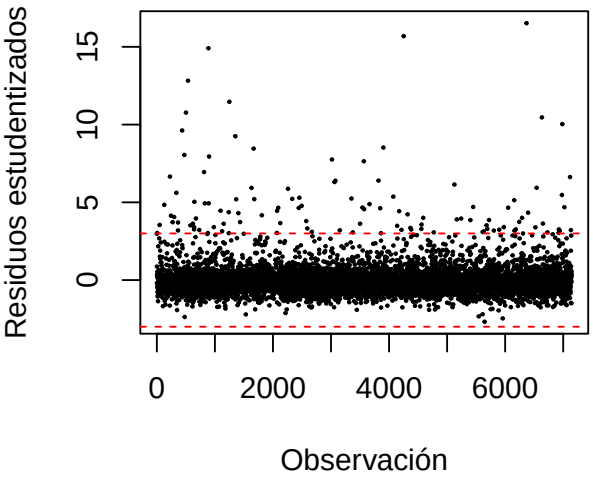

Se consideran outliers las observaciones con residuos $> |3|$. Se detectaron 115 observaciones atípicas por residuos estandarizados y 115 por estudentizados.

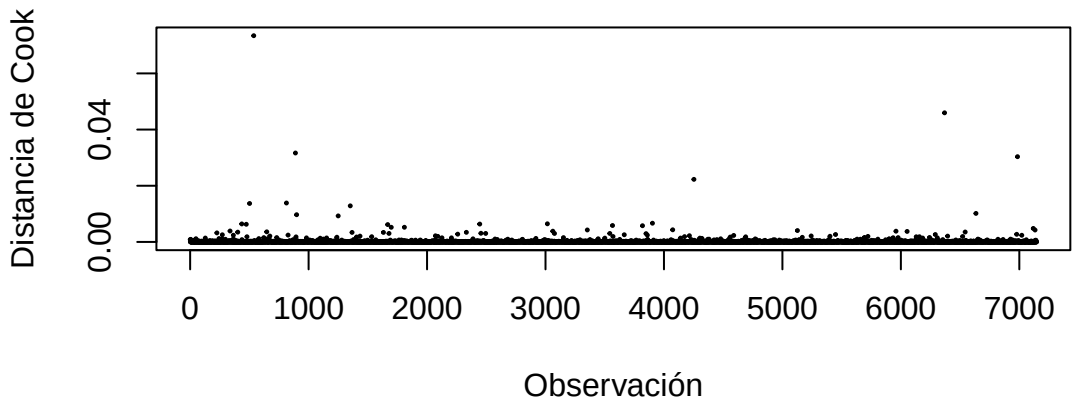

La Distancia de Cook (umbral = 1) no identifica observaciones influyentes (0 casos).

Sin embargo, al analizar DFBETAS ($> 2/\sqrt{n} = 0.0237$) se encontraron **1493** observaciones influyentes, y mediante DFFITS ($> 2\sqrt{p/n} = 0.1135$) se detectaron **216**. No se eliminan estas observaciones ya que representan la heterogeneidad real del mercado laboral argentino y no errores de medición.

1.6. Interpretación de coeficientes

	Estimación	Error Std.	t	p-valor
(Intercept)	117.8082	66.8915	1.7612	0.0783
formalSi	293.3404	16.8285	17.4312	0.0000
horas_trabajo	9.4570	0.4493	21.0491	0.0000
educ_catPrimario	75.9253	47.4484	1.6002	0.1096
educ_catSecundario	197.2788	47.0740	4.1908	0.0000
educ_catSuperior	554.6200	48.5421	11.4255	0.0000
regionGran Buenos Aires	150.8658	28.0525	5.3780	0.0000
regionNoreste	-87.5700	31.9630	-2.7397	0.0062
regionNoroeste	-113.5028	24.7453	-4.5868	0.0000
regionPampeana	87.1381	24.4345	3.5662	0.0004
regionPatagonia	382.0029	28.3875	13.4567	0.0000
ant_laboral1 a 5 años	-81.8032	17.2817	-4.7335	0.0000
ant_laboral6 meses a 1 año	-149.1938	34.9713	-4.2662	0.0000
ant_laboralEntre 3 y 6 meses	-115.1560	39.9429	-2.8830	0.0040
ant_laboral1 a 3 meses	-64.4796	37.9569	-1.6988	0.0894
ant_laboralMenos de 1 mes	-255.4889	72.4000	-3.5289	0.0004
ant_laboralDesconocido	-203.7208	27.1399	-7.5063	0.0000

	Estimación	Error Std.	t	p-valor
sexoMujer	-151.2938	15.0905	-10.0258	0.0000
est_civilseparado o divorciado	-118.0589	26.7519	-4.4131	0.0000
est_civilsoltero	-124.7733	19.8756	-6.2777	0.0000
est_civilunido	-52.7853	19.2243	-2.7458	0.0061
est_civilviudo	-116.7687	54.7448	-2.1330	0.0330
edad	3.8527	0.6842	5.6312	0.0000

El modelo en su conjunto es significativo (F = 193.21, p-valor < 2.2e-16).

$\hat{\beta}_0 = 117.81$. Ingreso esperado para un hombre soltero de Cuyo, sin educación, con más de 5 años de antigüedad, informal, con cero horas trabajadas y edad cero. No tiene sentido económico. p-valor: 0.0783 (no significativo al 5 %).

$\hat{\beta}_{formal} = 293.34$. Los trabajadores formales perciben $293 mil pesos más que los informales. p-valor: < 2e-16 (significativo al 5 %).

$\hat{\beta}_{horas} = 9.46$. Por cada hora semanal adicional, el ingreso aumenta en promedio $9.46 mil pesos. p-valor: < 2e-16 (significativo al 5 %).

$\hat{\beta}_{Primario} = 75.93$. Una persona con nivel Primario percibe $76 mil pesos más que una sin educación. p-valor: 0.11 (no significativo al 5 %).

$\hat{\beta}_{Secundario} = 197.28$. Una persona con nivel Secundario percibe $197 mil pesos más que una sin educación. p-valor: 2.81e-05 (significativo al 5 %).

$\hat{\beta}_{Superior} = 554.62$. Una persona con nivel Superior percibe $555 mil pesos más que una sin educación. p-valor: < 2e-16 (significativo al 5 %).

$\hat{\beta}_{GranBuenosAires} = 150.87$. Un residente de Gran Buenos Aires percibe $151 mil pesos más que uno de Cuyo. p-valor: 7.77e-08 (significativo al 5 %).

$\hat{\beta}_{Noreste} = -87.57$. Un residente de Noreste percibe $88 mil pesos menos que uno de Cuyo. p-valor: 0.00616 (significativo al 5 %).

$\hat{\beta}_{Noroeste} = -113.50$. Un residente de Noroeste percibe $114 mil pesos menos que uno de Cuyo. p-valor: 4.58e-06 (significativo al 5 %).

$\hat{\beta}_{Pampeana} = 87.14$. Un residente de Pampeana percibe $87 mil pesos más que uno de Cuyo. p-valor: 0.000365 (significativo al 5 %).

$\hat{\beta}_{Patagonia} = 382.00$. Un residente de Patagonia percibe $382 mil pesos más que uno de Cuyo. p-valor: < 2e-16 (significativo al 5 %).

$\hat{\beta}_{1a5aos} = -81.80$. Una persona con antigüedad “1 a 5 años” percibe $82 mil pesos menos que una con más de 5 años. p-valor: 2.25e-06 (significativo al 5 %).

$\hat{\beta}_{6mesesa1ao} = -149.19$. Una persona con antigüedad “6 meses a 1 año” percibe $149 mil pesos menos que una con más de 5 años. p-valor: 2.01e-05 (significativo al 5 %).

$\hat{\beta}_{Entre3y6meses} = -115.16$. Una persona con antigüedad “Entre 3 y 6 meses” percibe $115 mil pesos menos que una con más de 5 años. p-valor: 0.00395 (significativo al 5 %).

$\hat{\beta}_{1a3meses}$ = -64.48. Una persona con antigüedad "1 a 3 meses" percibe $64 mil pesos menos que una con más de 5 años. p-valor: 0.0894 (no significativo al 5 %).

$\hat{\beta}_{Menosde1mes}$ = -255.49. Una persona con antigüedad "Menos de 1 mes" percibe $255 mil pesos menos que una con más de 5 años. p-valor: 0.00042 (significativo al 5 %).

$\hat{\beta}_{Desconocido}$ = -203.72. Una persona con antigüedad "Desconocido" percibe $204 mil pesos menos que una con más de 5 años. p-valor: 6.82e-14 (significativo al 5 %).

$\hat{\beta}_{sexoMujer}$ = -151.29. Las mujeres perciben, en promedio, $151 mil pesos menos que los hombres, *ceteris paribus*. p-valor: $<$ 2e-16 (significativo al 5 %).

$\hat{\beta}_{separadoodivorciado}$ = -118.06. Una persona separado o divorciado percibe $118 mil pesos menos que una soltera. p-valor: 1.03e-05 (significativo al 5 %).

$\hat{\beta}_{soltero}$ = -124.77. Una persona soltero percibe $125 mil pesos menos que una soltera. p-valor: 3.64e-10 (significativo al 5 %).

$\hat{\beta}_{unido}$ = -52.79. Una persona unido percibe $53 mil pesos menos que una soltera. p-valor: 0.00605 (significativo al 5 %).

$\hat{\beta}_{viudo}$ = -116.77. Una persona viudo percibe $117 mil pesos menos que una soltera. p-valor: 0.033 (significativo al 5 %).

$\hat{\beta}_{edad}$ = 3.85. Por cada año adicional de edad, el ingreso aumenta en promedio $3.85 mil pesos. p-valor: 1.86e-08 (significativo al 5 %).

2. Consigna II: Regularización y Predicción

2.1. Preparación de datos

```
X_train <- model.matrix(M2, data = train)[, -1]
y_train <- train$ingreso_ocup
X_test  <- model.matrix(M2, data = test)[, -1]
y_test  <- test$ingreso_ocup
```

2.2. Ajuste Ridge

```
set.seed(2026)
cv_ridge <- cv.glmnet(x = X_train, y = y_train, alpha = 0, nfolds = 10)
plot(cv_ridge)
```

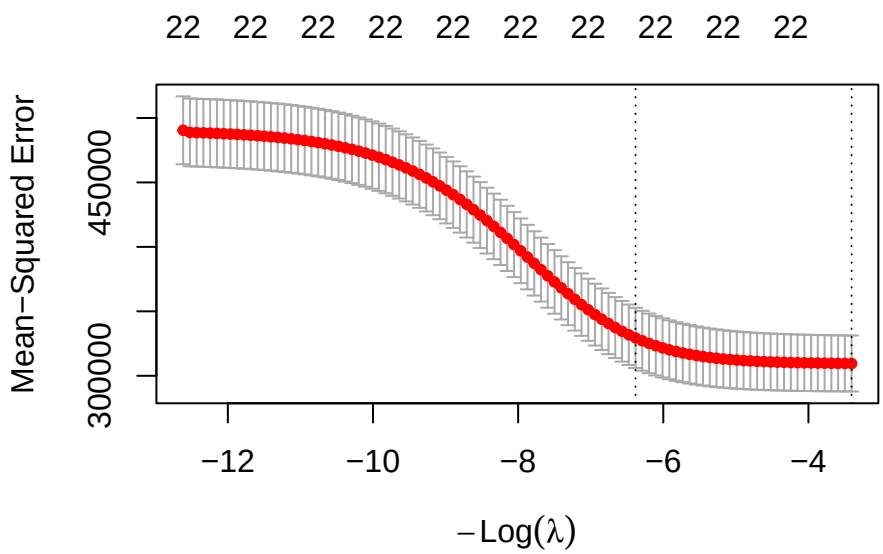


```
Lambda mínimo: 30.1279

Lambda 1se:    591.4236
```

Se elige $\lambda_{min} = 30.1279$ (el que minimiza el error de CV). También se reporta $\lambda_{1se} = 591.4236$ (modelo más parsimonioso a 1 desvío estándar del mínimo).

	MCO	Ridge
(Intercept)	117.8082	293.0017
formalSi	293.3404	293.2672
horas_trabajo	9.4570	9.1004
educ_catPrimario	75.9253	-71.6830
educ_catSecundario	197.2788	44.9616
educ_catSuperior	554.6200	388.8480
regionGran Buenos Aires	150.8658	131.0781
regionNoreste	-87.5700	-97.6264
regionNoroeste	-113.5028	-126.8265
regionPampeana	87.1381	67.8639
regionPatagonia	382.0029	353.7324
ant_laboral1 a 5 años	-81.8032	-80.4494
ant_laboral6 meses a 1 año	-149.1938	-146.4742
ant_laboralEntre 3 y 6 meses	-115.1560	-113.7548
ant_laboral1 a 3 meses	-64.4796	-67.5804
ant_laboralMenos de 1 mes	-255.4889	-257.9636
ant_laboralDesconocido	-203.7208	-213.1316
sexoMujer	-151.2938	-143.0357
est_civilseparado o divorciado	-118.0589	-107.2167
est_civilsoltero	-124.7733	-115.9327
est_civilunido	-52.7853	-45.2087
est_civilviudo	-116.7687	-117.6787
edad	3.8527	3.7402

Los coeficientes Ridge son levemente menores en valor absoluto que los de MCO, lo cual es esperable ya que la penalización L_2 los encoge hacia cero.

2.3. Ajuste Lasso

```
set.seed(2026)
cv_lasso <- cv.glmnet(x = X_train, y = y_train, alpha = 1, nfolds = 10)
plot(cv_lasso)
```

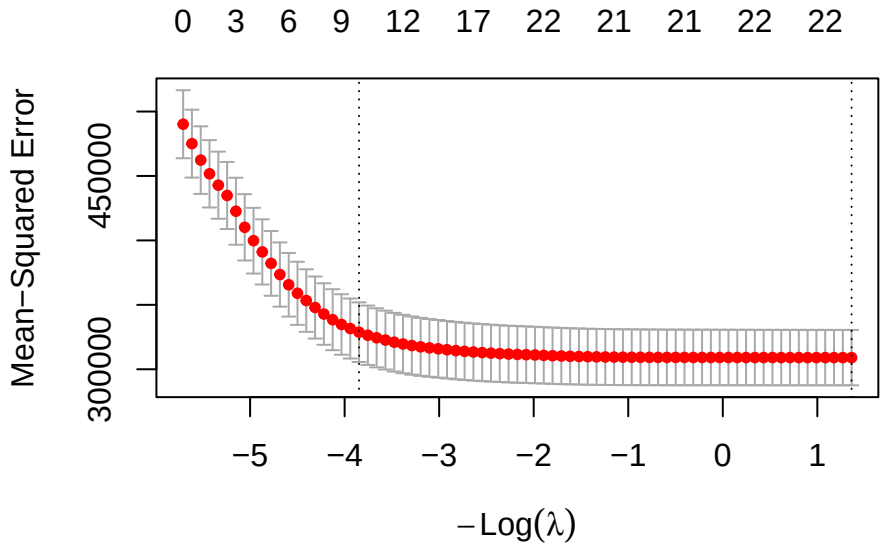


```
Lambda mínimo: 0.256

Lambda 1se:    46.8693
```

Se elige $\lambda_{min} = 0.256$. Se reporta también $\lambda_{1se} = 46.8693$.

	MCO	Lasso
(Intercept)	117.8082	139.5053
formalSi	293.3404	294.5096
horas_trabajo	9.4570	9.4465
educ_catPrimario	75.9253	52.8160
educ_catSecundario	197.2788	174.2966
educ_catSuperior	554.6200	531.5942
regionGran Buenos Aires	150.8658	149.0517
regionNoreste	-87.5700	-87.6623
regionNoroeste	-113.5028	-114.2479
regionPampeana	87.1381	85.3410
regionPatagonia	382.0029	380.1927
ant_laboral1 a 5 años	-81.8032	-80.8984
ant_laboral6 meses a 1 año	-149.1938	-147.3181
ant_laboralEntre 3 y 6 meses	-115.1560	-112.9175
ant_laboral1 a 3 meses	-64.4796	-62.4995
ant_laboralMenos de 1 mes	-255.4889	-252.9273
ant_laboralDesconocido	-203.7208	-203.0870
sexoMujer	-151.2938	-150.7364
est_civilseparado o divorciado	-118.0589	-115.8818

	MCO	Lasso
est_civilsoltero	-124.7733	-123.1693
est_civilunido	-52.7853	-51.1823
est_civilviudo	-116.7687	-114.5632
edad	3.8527	3.8414

Lasso no descartó ninguna variable en este caso.

2.4. Evaluación predictiva (datos de prueba)

```
pred_mco   <- predict(M2, newdata = test)
pred_ridge <- as.vector(predict(m_ridge, newx = X_test, s = cv_ridge$lambda.min))
pred_lasso <- as.vector(predict(m_lasso, newx = X_test, s = cv_lasso$lambda.min))

sct <- sum((y_test - mean(y_test))^2)
r2_train <- summary(M2)$r.squared
```

Modelo	CME Test	R^2 Train	R^2 Test	Variación R^2
MCO	301227.1	0.3738	0.3767	0.78 %
Ridge	301360.1	0.3738	0.3765	0.72 %
Lasso	301185.5	0.3738	0.3768	0.8 %

El modelo más adecuado según el CME de prueba es **Lasso**. Los tres modelos presentan resultados muy similares, lo cual es esperable: en escenarios donde $n >> p$ y no hay multicolinealidad severa, el sesgo introducido por la penalización no mejora sustancialmente la varianza del estimador MCO, validando la robustez del modelo original.

3. Consigna III: Regresión Logística

3.1. Definición de la variable respuesta

```
datos_logit <- datos_modelo %>%
  mutate(Y = ifelse(ingreso_ocup >= 1000, 1, 0))
```

$Y_i = 0$ si ingreso < 1000 | $Y_i = 1$ si ingreso ≥ 1000. Proporción de éxitos: 0.3468.

3.2. Partición con createDataPartition

```
set.seed(2026)
idx_logit <- createDataPartition(datos_logit$Y, p = 0.70, list = FALSE)
train_logit <- datos_logit[idx_logit, ]
test_logit  <- datos_logit[-idx_logit, ]
```

Proporción $Y = 1$ en train: 0.3508 | en test: 0.3374. La función `createDataPartition()` garantiza que ambas proporciones sean similares.

3.3. Modelo de regresión logística

Se ajusta con las mismas variables del modelo ganador M2:

```
vars_m2 <- attr(terms(M2), "term.labels")
formula_logit <- as.formula(paste("Y ~", paste(vars_m2, collapse = " + ")))
MLog <- glm(formula_logit, data = train_logit, family = binomial(link = "logit"))
```

	Estimación	Error Std.	z	p-valor
(Intercept)	-5.1541	0.4029	-12.7918	0.0000
formalSi	1.5943	0.0914	17.4438	0.0000
horas_trabajo	0.0437	0.0024	17.9000	0.0000
educ_catPrimario	0.5893	0.3181	1.8527	0.0639
educ_catSecundario	1.4245	0.3143	4.5318	0.0000
educ_catSuperior	2.4766	0.3186	7.7735	0.0000
regionGran Buenos Aires	0.5660	0.1312	4.3138	0.0000
regionNoreste	-0.5612	0.1555	-3.6084	0.0003
regionNoroeste	-0.8068	0.1244	-6.4834	0.0000
regionPampeana	0.3720	0.1174	3.1693	0.0015
regionPatagonia	1.7073	0.1376	12.4081	0.0000
ant_laboral1 a 5 años	-0.3446	0.0788	-4.3710	0.0000
ant_laboral6 meses a 1 año	-0.5495	0.1842	-2.9827	0.0029
ant_laboralEntre 3 y 6 meses	-0.9160	0.2306	-3.9723	0.0001

	Estimación	Error Std.	z	p-valor
ant_laboral1 a 3 meses	-0.6338	0.2281	-2.7780	0.0055
ant_laboralMenos de 1 mes	-1.2181	0.4978	-2.4468	0.0144
ant_laboralDesconocido	-2.0460	0.2710	-7.5507	0.0000
sexoMujer	-0.7320	0.0717	-10.2149	0.0000
est_civilseparado o divorciado	-0.5348	0.1277	-4.1876	0.0000
est_civilsoltero	-0.5344	0.0920	-5.8074	0.0000
est_civilunido	-0.1571	0.0872	-1.8020	0.0715
est_civilviudo	-0.5077	0.2930	-1.7325	0.0832
edad	0.0196	0.0034	5.7979	0.0000

3.3.1. Razones de odds (predictores significativos al 5 %, test de Wald)

No interpretamos los coeficientes crudos (log-odds) sino las razones de odds, que resultan de exponenciar los $\widehat{\beta}$:

	OR	IC 2.5 %	IC 97.5 %	Variación	p-valor
(Intercept)	0.0058	0.0026	0.0127	-99.4 %	< 2e-16
formalSi	4.9248	4.1171	5.8909	392.5 %	< 2e-16
horas_trabajo	1.0446	1.0397	1.0496	4.5 %	< 2e-16
educ_catSecundario	4.1559	2.2444	7.6956	315.6 %	5.85e-06
educ_catSuperior	11.9005	6.3734	22.2206	1090 %	7.64e-15
regionGran Buenos Aires	1.7612	1.3618	2.2776	76.1 %	1.6e-05
regionNoreste	0.5705	0.4206	0.7739	-42.9 %	0.000308
regionNoroeste	0.4463	0.3497	0.5696	-55.4 %	8.97e-11
regionPampeana	1.4507	1.1525	1.8259	45.1 %	0.00153
regionPatagonia	5.5141	4.2107	7.2210	451.4 %	< 2e-16
ant_laboral1 a 5 años	0.7085	0.6071	0.8269	-29.1 %	1.24e-05
ant_laboral6 meses a 1 año	0.5772	0.4023	0.8283	-42.3 %	0.00286
ant_laboralEntre 3 y 6 meses	0.4001	0.2546	0.6287	-60 %	7.12e-05
ant_laboral1 a 3 meses	0.5306	0.3393	0.8298	-46.9 %	0.00547
ant_laboralMenos de 1 mes	0.2958	0.1115	0.7848	-70.4 %	0.0144
ant_laboralDesconocido	0.1292	0.0760	0.2198	-87.1 %	4.33e-14
sexoMujer	0.4809	0.4179	0.5535	-51.9 %	< 2e-16
est_civilseparado o divorciado	0.5858	0.4561	0.7524	-41.4 %	2.82e-05
est_civilsoltero	0.5860	0.4893	0.7019	-41.4 %	6.34e-09
edad	1.0198	1.0131	1.0266	2 %	6.71e-09

Interpretación (solo predictores significativos, *ceteris paribus*):

- **Formal** (OR = 4.92): estar registrado incrementa la chance en un 392.5 % respecto a los informales.
- **Horas trabajo** (OR = 1.04): cada hora semanal adicional incrementa la chance en un 4.5 %.
- **Educación Secundario** (OR = 4.16): la chance es un 315.6 % mayor que sin educación.

- **Educación Superior** (OR = 11.90): la chance es un 1090.0 % mayor que sin educación.
- **Región Gran Buenos Aires** (OR = 1.76): la chance es un 76.1 % mayor que en Cuyo.
- **Región Noreste** (OR = 0.57): la chance es un 42.9 % menor que en Cuyo.
- **Región Noroeste** (OR = 0.45): la chance es un 55.4 % menor que en Cuyo.
- **Región Pampeana** (OR = 1.45): la chance es un 45.1 % mayor que en Cuyo.
- **Región Patagonia** (OR = 5.51): la chance es un 451.4 % mayor que en Cuyo.
- **Antigüedad 1 a 5 años** (OR = 0.71): la chance es un 29.1 % menor que con más de 5 años.
- **Antigüedad 6 meses a 1 año** (OR = 0.58): la chance es un 42.3 % menor que con más de 5 años.
- **Antigüedad Entre 3 y 6 meses** (OR = 0.40): la chance es un 60.0 % menor que con más de 5 años.
- **Antigüedad 1 a 3 meses** (OR = 0.53): la chance es un 46.9 % menor que con más de 5 años.
- **Antigüedad Menos de 1 mes** (OR = 0.30): la chance es un 70.4 % menor que con más de 5 años.
- **Antigüedad Desconocido** (OR = 0.13): la chance es un 87.1 % menor que con más de 5 años.
- **Sexo Mujer** (OR = 0.48): ser mujer reduce la chance de superar los $1.000 mil en un 51.9 % respecto a los hombres.
- **separado o divorciado** (OR = 0.59): la chance es un 41.4 % menor que para solteros.
- **soltero** (OR = 0.59): la chance es un 41.4 % menor que para solteros.
- **Edad** (OR = 1.02): cada año adicional incrementa la chance en un 2.0 %.

3.4. Punto de corte óptimo (Curva ROC)

```
curvaROC <- roc(train_logit$Y, fitted.values(MLog), quiet = TRUE)
plot(curvaROC, print.auc = TRUE, print.thres = TRUE)
```

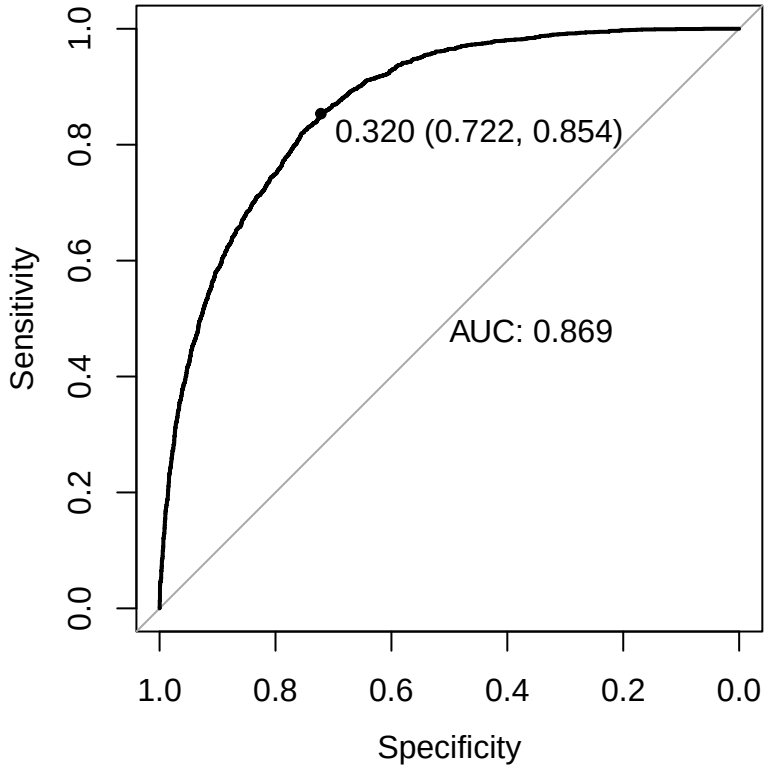

El punto de corte óptimo es **0.3199**, hallado mediante la curva ROC para maximizar simultáneamente sensibilidad y especificidad. Notar que no se utilizó el umbral de 0.5 por defecto, sino que se eligió este valor óptimo. El AUC es **0.869**.

3.5. Clasificación y Matriz de Confusión (datos de prueba)

```
prob_test  <- predict(MLog, newdata = test_logit, type = "response")
pred_clase <- factor(ifelse(prob_test >= corte, 1, 0), levels = c("0","1"))
real_clase <- factor(test_logit$Y, levels = c("0","1"))
mc <- confusionMatrix(pred_clase, real_clase, positive = "1")
```

	0	1
0	1453	155
1	576	878

3.5.1. Métricas de clasificación

Metrica	Valor
Precisión (Accuracy)	0.7613
Sensibilidad	0.8500
Especificidad	0.7161
VPP	0.6039
VPN	0.9036

Precisión (0.7613): el 76.1 % de los individuos fueron correctamente clasificados.

Sensibilidad (0.85): el modelo detectó correctamente al 85 % de los individuos con ingreso ≥ 1000 (verdaderos positivos).

Especificidad (0.7161): el modelo identificó correctamente al 71.6 % de los individuos con ingreso < 1000 (verdaderos negativos).

VPP (0.6039): cuando el modelo predice Y=1, acierta el 60.4 % de las veces.

VPN (0.9036): cuando el modelo predice Y=0, acierta el 90.4 % de las veces.